

Numerická lineární algebra 1

Řešení soustav lineárních rovnic - iterační metody (Jacobiho, Gaussova-Seidelova, Richardsonova metoda)

Michal Merta

VŠB – Technická univerzita Ostrava

michal.merta@vsb.cz

30. března 2023

Motivace

- Přímé metody (LU, LDLT, Choleského faktorizace, atd.) vyžadují $\mathcal{O}(m^3)$ operací \Rightarrow omezená velikost soustavy, kterou jsme schopni řešit.

Motivace

- Přímé metody (LU, LDLT, Choleského faktorizace, atd.) vyžadují $\mathcal{O}(m^3)$ operací \Rightarrow omezená velikost soustavy, kterou jsme schopni řešit.
- V případě husté matice $A \in \mathbb{R}^{n \times n}$ se přibližná velikost soustavy řešitelné přímými metodami historicky vyvíjela takto:
 - 1950: $n = 20$ (Wilkinson)

Motivace

- Přímé metody (LU, LDLT, Choleského faktorizace, atd.) vyžadují $\mathcal{O}(m^3)$ operací \Rightarrow omezená velikost soustavy, kterou jsme schopni řešit.
- V případě husté matice $A \in \mathbb{R}^{n \times n}$ se přibližná velikost soustavy řešitelné přímými metodami historicky vyvíjela takto:
 - 1950: $n = 20$ (Wilkinson)
 - 1965: $n = 200$ (Forsythe a Moler)

Motivace

- Přímé metody (LU, LDLT, Choleského faktorizace, atd.) vyžadují $\mathcal{O}(m^3)$ operací \Rightarrow omezená velikost soustavy, kterou jsme schopni řešit.
- V případě husté matice $A \in \mathbb{R}^{n \times n}$ se přibližná velikost soustavy řešitelné přímými metodami historicky vyvíjela takto:
 - 1950: $n = 20$ (Wilkinson)
 - 1965: $n = 200$ (Forsythe a Moler)
 - 1980: $n = 2000$ (LINPACK)

Motivace

- Přímé metody (LU, LDLT, Choleského faktorizace, atd.) vyžadují $\mathcal{O}(m^3)$ operací \Rightarrow omezená velikost soustavy, kterou jsme schopni řešit.
- V případě husté matice $A \in \mathbb{R}^{n \times n}$ se přibližná velikost soustavy řešitelné přímými metodami historicky vyvíjela takto:
 - 1950: $n = 20$ (Wilkinson)
 - 1965: $n = 200$ (Forsythe a Moler)
 - 1980: $n = 2000$ (LINPACK)
 - 1995: $n = 20000$ (LAPACK)

Motivace

- Přímé metody (LU, LDLT, Choleského faktorizace, atd.) vyžadují $\mathcal{O}(m^3)$ operací \Rightarrow omezená velikost soustavy, kterou jsme schopni řešit.
- V případě husté matice $A \in \mathbb{R}^{n \times n}$ se přibližná velikost soustavy řešitelné přímými metodami historicky vyvíjela takto:
 - 1950: $n = 20$ (Wilkinson)
 - 1965: $n = 200$ (Forsythe a Moler)
 - 1980: $n = 2000$ (LINPACK)
 - 1995: $n = 20000$ (LAPACK)
 - 2010: $n = 200000$ (HDSS)

- V případě systémů s řídkou maticí jsme schopni řešit přímými řešiči soustavy s větší dimenzí (desítky, stovky miliónů neznámých). Může ale dojít k zaplnění matice.

- V případě systémů s řídkou maticí jsme schopni řešit přímými řešiči soustavy s větší dimenzí (desítky, stovky miliónů neznámých). Může ale dojít k zaplnění matice.

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & 0 & 0 & 0 \\ \times & 0 & \times & 0 & 0 \\ \times & 0 & 0 & \times & 0 \\ \times & 0 & 0 & 0 & \times \end{bmatrix}$$

- V případě systémů s řídkou maticí jsme schopni řešit přímými řešiči soustavy s větší dimenzí (desítky, stovky miliónů neznámých). Může ale dojít k zaplnění matice.

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & 0 & 0 & 0 \\ \times & 0 & \times & 0 & 0 \\ \times & 0 & 0 & \times & 0 \\ \times & 0 & 0 & 0 & \times \end{bmatrix} \rightarrow \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \end{bmatrix}$$

- V případě systémů s řídkou maticí jsme schopni řešit přímými řešiči soustavy s větší dimenzí (desítky, stovky miliónů neznámých). Může ale dojít k zaplnění matice.

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & 0 & 0 & 0 \\ \times & 0 & \times & 0 & 0 \\ \times & 0 & 0 & \times & 0 \\ \times & 0 & 0 & 0 & \times \end{bmatrix} \rightarrow \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \end{bmatrix}$$

- Tento problém lze částečně řešit vhodnou pivotizací matice před rozkladem.

- V případě systémů s řídkou maticí jsme schopni řešit přímými řešiči soustavy s větší dimenzí (desítky, stovky miliónů neznámých). Může ale dojít k zaplnění matice.


$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & 0 & 0 & 0 \\ \times & 0 & \times & 0 & 0 \\ \times & 0 & 0 & \times & 0 \\ \times & 0 & 0 & 0 & \times \end{bmatrix} \rightarrow \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \end{bmatrix}$$

- Tento problém lze částečně řešit vhodnou pivotizací matice před rozkladem.
- Používají se tzv. *approximated minimum degree (AMD)* algoritmy (colamd, symamd).

- V případě systémů s řídkou maticí jsme schopni řešit přímými řešiči soustavy s větší dimenzí (desítky, stovky miliónů neznámých). Může ale dojít k zaplnění matice.

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & 0 & 0 & 0 \\ \times & 0 & \times & 0 & 0 \\ \times & 0 & 0 & \times & 0 \\ \times & 0 & 0 & 0 & \times \end{bmatrix} \rightarrow \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \end{bmatrix}$$





- Tento problém lze částečně řešit vhodnou pivotizací matice před rozkladem.
- Používají se tzv. *approximated minimum degree (AMD)* algoritmy (colamd, symamd).



- V případě systémů s řídkou maticí jsme schopni řešit přímými řešiči soustavy s větší dimenzí (desítky, stovky miliónů neznámých). Může ale dojít k zaplnění matice.

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & 0 & 0 & 0 \\ \times & 0 & \times & 0 & 0 \\ \times & 0 & 0 & \times & 0 \\ \times & 0 & 0 & 0 & \times \end{bmatrix} \rightarrow \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \end{bmatrix}$$

- Tento problém lze částečně řešit vhodnou pivotizací matice před rozkladem.
- Používají se tzv. *approximated minimum degree (AMD)* algoritmy (colamd, symamd).



■ Další nevýhody přímých řešičů

- Známe-li přibližné řešení, nedokážeme tuto znalost využít ke snížení celkového počtu operací a zkrácení doby výpočtu.
- Postačuje-li nám pouze přibližné řešení, nemůžeme výpočet pomocí přímého řešiče ukončit předčasně.

- Další nevýhody přímých řešičů
 - Známe-li přibližné řešení, nedokážeme tuto znalost využít ke snížení celkového počtu operací a zkrácení doby výpočtu.
 - Postačuje-li nám pouze přibližné řešení, nemůžeme výpočet pomocí přímého řešiče ukončit předčasně.
- Alternativou jsou *iterační řešiče*
 - Generují posloupnost přibližných řešení $\{x^k\}$.
 - Pracují téměř výhradně s násobením matice-vektor ($\mathcal{O}(n^2)$) \Rightarrow nedochází k zaplnění matice.
 - Důležitou vlastností je rychlost konvergence $\{x^k\}$ k řešení.
 - Nevýhoda – pro některé matice může iterační metoda konvergovat k řešení pomalu, nebo vůbec.
- Budeme se zabývat *lineárními* a *gradientními* iteračními metodami.

Lineární iterační metody

- Bud' x^0 dané. Hledáme posloupnost přibližných řešení rovnice $Ax = b$, $A \in \mathbb{R}^{n \times n}$ ve tvaru

$$x^{k+1} = Mx^k + Nb,$$

kde $M, N \in \mathbb{R}^{n \times n}$.

Lineární iterační metody

- Bud' \mathbf{x}^0 dané. Hledáme posloupnost přibližných řešení rovnice $A\mathbf{x} = \mathbf{b}$, $A \in \mathbb{R}^{n \times n}$ ve tvaru

$$\mathbf{x}^{k+1} = M\mathbf{x}^k + N\mathbf{b},$$

kde $M, N \in \mathbb{R}^{n \times n}$.

Definice

Řekneme, že iterační metoda je *konvergentní*, pokud $\mathbf{x}^k \rightarrow \mathbf{x} = A^{-1}\mathbf{b}$ pro $k \rightarrow \infty$ (tedy $\lim_{k \rightarrow \infty} \mathbf{x}^k = \mathbf{x}$). Toto platí právě tehdy, když $\|M\| < 1$.

Lineární iterační metody

- Bud' \mathbf{x}^0 dané. Hledáme posloupnost přibližných řešení rovnice $A\mathbf{x} = \mathbf{b}$, $A \in \mathbb{R}^{n \times n}$ ve tvaru

$$\mathbf{x}^{k+1} = M\mathbf{x}^k + N\mathbf{b},$$

kde $M, N \in \mathbb{R}^{n \times n}$.

Definice

Řekneme, že iterační metoda je *konvergentní*, pokud $\mathbf{x}^k \rightarrow \mathbf{x} = A^{-1}\mathbf{b}$ pro $k \rightarrow \infty$ (tedy $\lim_{k \rightarrow \infty} \mathbf{x}^k = \mathbf{x}$). Toto platí právě tehdy, když $\|M\| < 1$.

Definice

Řekneme, že iterační metoda je *konzistentní* se soustavou $A\mathbf{x} = \mathbf{b}$, řeší-li soustavu $M\tilde{\mathbf{x}} + N\mathbf{b} = \tilde{\mathbf{x}}$ právě jeden vektor $\mathbf{x} = A^{-1}\mathbf{b}$. Toto platí právě tehdy, když $M = I - NA$.

- Při odvozování následujících metod budeme vycházet z rozkladu matice A na součet diagonální, dolní a horní trojúhelníkové matice

$$A = D + L + U$$

- Při odvozování následujících metod budeme vycházet z rozkladu matice A na součet diagonální, dolní a horní trojúhelníkové matice

$$A = D + L + U$$

- Např. matici

$$A = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

rozložíme na

$$L = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}, D = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}, U = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}.$$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

$$Ax = b$$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

$$Ax = b$$

$$(D + L + U)x = b$$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

$$Ax = b$$

$$(D + L + U)x = b$$

$$Dx + (L + U)x = b$$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

$$Ax = b$$

$$(D + L + U)x = b$$

$$Dx + (L + U)x = b$$

$$Dx = -(L + U)x + b$$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

$$Ax = b$$

$$(D + L + U)x = b$$

$$Dx + (L + U)x = b$$

$$Dx = -(L + U)x + b$$

$$Dx^{k+1} = -(L + U)x^k + b$$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

$$Ax = b$$

$$(D + L + U)x = b$$

$$Dx + (L + U)x = b$$

$$Dx = -(L + U)x + b$$

$$Dx^{k+1} = -(L + U)x^k + b$$

$$x^{k+1} = \underbrace{-D^{-1}(L + U)x^k}_{=M} + \underbrace{D^{-1}b}_{=N} = D^{-1}(b - (L + U)x^k)$$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

$$A\mathbf{x} = \mathbf{b}$$

$$(D + L + U)\mathbf{x} = \mathbf{b}$$

$$D\mathbf{x} + (L + U)\mathbf{x} = \mathbf{b}$$

$$D\mathbf{x} = -(L + U)\mathbf{x} + \mathbf{b}$$

$$D\mathbf{x}^{k+1} = -(L + U)\mathbf{x}^k + \mathbf{b}$$

$$\mathbf{x}^{k+1} = \underbrace{-D^{-1}(L + U)\mathbf{x}^k}_{=M} + \underbrace{D^{-1}\mathbf{b}}_{=N} = D^{-1}(\mathbf{b} - (L + U)\mathbf{x}^k)$$

$$i = 1, \dots, n: (\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} (\mathbf{x}^k)_j \right) = \frac{1}{a_{i,i}} \left(b_i - \sum_{j < i}^n a_{i,j} (\mathbf{x}^k)_j - \sum_{j > i}^n a_{i,j} (\mathbf{x}^k)_j \right)$$

Jacobiho metoda

- Vyjdeme z rozkladu $A = D + L + U$

$$A\mathbf{x} = \mathbf{b}$$

$$(D + L + U)\mathbf{x} = \mathbf{b}$$

$$D\mathbf{x} + (L + U)\mathbf{x} = \mathbf{b}$$

$$D\mathbf{x} = -(L + U)\mathbf{x} + \mathbf{b}$$

$$D\mathbf{x}^{k+1} = -(L + U)\mathbf{x}^k + \mathbf{b}$$

$$\mathbf{x}^{k+1} = \underbrace{-D^{-1}(L + U)\mathbf{x}^k}_{=M} + \underbrace{D^{-1}\mathbf{b}}_{=N} = D^{-1}(\mathbf{b} - (L + U)\mathbf{x}^k)$$

$$i = 1, \dots, n: (\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} (\mathbf{x}^k)_j \right) = \frac{1}{a_{i,i}} \left(b_i - \sum_{j < i}^n a_{i,j} (\mathbf{x}^k)_j - \sum_{j > i}^n a_{i,j} (\mathbf{x}^k)_j \right)$$

- Metoda je konzistentní – vyplývá už z konstrukce, ale můžeme ověřit, že $M = I - NA$:

$$M = -D^{-1}(L + U), \quad N = D^{-1}$$

$$I - NA =$$

- Metoda je konzistentní – vyplývá už z konstrukce, ale můžeme ověřit, že $M = I - NA$:

$$M = -D^{-1}(L + U), \quad N = D^{-1}$$

$$I - NA = I - D^{-1}A$$

- Metoda je konzistentní – vyplývá už z konstrukce, ale můžeme ověřit, že $M = I - NA$:

$$M = -D^{-1}(L + U), \quad N = D^{-1}$$

$$I - NA = I - D^{-1}A = I - D^{-1}(L + D + U)$$

- Metoda je konzistentní – vyplývá už z konstrukce, ale můžeme ověřit, že $M = I - NA$:

$$M = -D^{-1}(L + U), \quad N = D^{-1}$$

$$\begin{aligned} I - NA &= I - D^{-1}A = I - D^{-1}(L + D + U) \\ &= I - D^{-1}(L + U) - D^{-1}D \end{aligned}$$

- Metoda je konzistentní – vyplývá už z konstrukce, ale můžeme ověřit, že $M = I - NA$:

$$M = -D^{-1}(L + U), \quad N = D^{-1}$$

$$\begin{aligned} I - NA &= I - D^{-1}A = I - D^{-1}(L + D + U) \\ &= I - D^{-1}(L + U) - D^{-1}D = -D^{-1}(L + U) \end{aligned}$$

- Metoda je konzistentní – vyplývá už z konstrukce, ale můžeme ověřit, že $M = I - NA$:

$$M = -D^{-1}(L + U), \quad N = D^{-1}$$

$$\begin{aligned} I - NA &= I - D^{-1}A = I - D^{-1}(L + D + U) \\ &= I - D^{-1}(L + U) - D^{-1}D = -D^{-1}(L + U) = M \end{aligned}$$

Definice

Matici $A \in \mathbb{R}^{n \times n}$ nazveme ostře diagonálně dominantní, platí-li

$$\sum_{\substack{j=1 \\ j \neq i}} |a_{i,j}| < |a_{i,i}|, \quad \text{pro všechna } i = 1, \dots, n.$$

Definice

Matici $A \in \mathbb{R}^{n \times n}$ nazveme ostře diagonálně dominantní, platí-li

$$\sum_{\substack{j=1 \\ j \neq i}} |a_{i,j}| < |a_{i,i}|, \quad \text{pro všechna } i = 1, \dots, n.$$

Věta

Bud' $A \in \mathbb{R}^{n \times n}$ ostře diagonálně dominantní matice. Pak posloupnost $\{x^k\}$ generovaná Jacobiho metodou konverguje k řešení x soustavy $Ax = b$ pro libovolně zvolený počáteční odhad x^0 .

Důkaz.

$$x_i^{k+1} = \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j^k \right)$$

Důkaz.

$$\begin{aligned}x_i^{k+1} &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j^k \right) \\ x_i &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j \right)\end{aligned}$$

Důkaz.

$$\begin{aligned}x_i^{k+1} &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j^k \right) \\x_i &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j \right) \\\underbrace{x_i^{k+1} - x_i}_{=e_i^{k+1}} &= -\frac{1}{a_{i,i}} \left(\sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} \underbrace{(x_j^k - x_j)}_{e_j^k} \right)\end{aligned}$$

Důkaz.

$$\begin{aligned}
 x_i^{k+1} &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j^k \right) \\
 x_i &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j \right) \\
 \underbrace{x_i^{k+1} - x_i}_{=e_i^{k+1}} &= -\frac{1}{a_{i,i}} \left(\sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} \underbrace{(x_j^k - x_j)}_{e_j^k} \right)
 \end{aligned}$$

$$|e_i^{k+1}| \leq \frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}| |e_j^k|$$

Důkaz.

$$\begin{aligned}
 x_i^{k+1} &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j^k \right) \\
 x_i &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j \right) \\
 \underbrace{x_i^{k+1} - x_i}_{=e_i^{k+1}} &= -\frac{1}{a_{i,i}} \left(\sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} \underbrace{(x_j^k - x_j)}_{e_j^k} \right)
 \end{aligned}$$

$$|e_i^{k+1}| \leq \frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}| |e_j^k| \leq \frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}| \max_{j=1, \dots, n} |e_j^k|$$

Důkaz.

$$\begin{aligned}
 x_i^{k+1} &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j^k \right) \\
 x_i &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j \right) \\
 \underbrace{x_i^{k+1} - x_i}_{=e_i^{k+1}} &= -\frac{1}{a_{i,i}} \left(\sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} \underbrace{(x_j^k - x_j)}_{e_j^k} \right)
 \end{aligned}$$

$$\begin{aligned}
 |e_i^{k+1}| &\leq \frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}| |e_j^k| \leq \frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}| \max_{j=1, \dots, n} |e_j^k| = \\
 &= \max_{j=1, \dots, n} |e_j^k| \underbrace{\frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}|}_{<1}
 \end{aligned}$$

Důkaz.

$$\begin{aligned}
 x_i^{k+1} &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j^k \right) \\
 x_i &= \frac{1}{a_{i,i}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j \right) \\
 \underbrace{x_i^{k+1} - x_i}_{=e_i^{k+1}} &= -\frac{1}{a_{i,i}} \left(\sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} \underbrace{(x_j^k - x_j)}_{e_j^k} \right)
 \end{aligned}$$

$$\begin{aligned}
 |e_i^{k+1}| &\leq \frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}| |e_j^k| \leq \frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}| \max_{j=1, \dots, n} |e_j^k| = \\
 &= \max_{j=1, \dots, n} |e_j^k| \underbrace{\frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}|}_{<1} < \max_{j=1, \dots, n} |e_j^k|
 \end{aligned}$$

□

Gaussova-Seidelova metoda

- Zopakujme předpis pro i . prvek vektoru \mathbf{x}^{k+1} v případě Jacobiho metody:

$$(\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j < i}^n a_{i,j} (\mathbf{x}^k)_j - \sum_{j > i}^n a_{i,j} (\mathbf{x}^k)_j \right)$$

Gaussova-Seidelova metoda

- Zopakujme předpis pro i . prvek vektoru \mathbf{x}^{k+1} v případě Jacobiho metody:

$$(\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j<i}^n a_{i,j}(\mathbf{x}^k)_j - \sum_{j>i}^n a_{i,j}(\mathbf{x}^k)_j \right)$$

- Prvky vektoru \mathbf{x}^k v sumě $\sum_{j<i}^n a_{i,j}(\mathbf{x}^k)_j$ můžeme nahradit již známými prvky vektoru \mathbf{x}^{k+1}

$$(\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j<i}^n a_{i,j}(\mathbf{x}^{k+1})_j - \sum_{j>i}^n a_{i,j}(\mathbf{x}^k)_j \right)$$

Gaussova-Seidelova metoda

- Zopakujme předpis pro i . prvek vektoru \mathbf{x}^{k+1} v případě Jacobiho metody:

$$(\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j < i}^n a_{i,j} (\mathbf{x}^k)_j - \sum_{j > i}^n a_{i,j} (\mathbf{x}^k)_j \right)$$

- Prvky vektoru \mathbf{x}^k v sumě $\sum_{j < i}^n a_{i,j} (\mathbf{x}^k)_j$ můžeme nahradit již známými prvky vektoru \mathbf{x}^{k+1}

$$(\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j < i}^n a_{i,j} (\mathbf{x}^{k+1})_j - \sum_{j > i}^n a_{i,j} (\mathbf{x}^k)_j \right)$$

- Maticový zápis můžeme opět snadno odvodit, rozdělíme-li $A = L + D + U$ a ponecháme-li u vektoru \mathbf{x}^{k+1} součet $(L + D)$

$$(L + D)\mathbf{x}^{k+1} = \mathbf{b} - U\mathbf{x}^k,$$

Gaussova-Seidelova metoda

- Zopakujme předpis pro i . prvek vektoru \mathbf{x}^{k+1} v případě Jacobiho metody:

$$(\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j < i}^n a_{i,j} (\mathbf{x}^k)_j - \sum_{j > i}^n a_{i,j} (\mathbf{x}^k)_j \right)$$

- Prvky vektoru \mathbf{x}^k v sumě $\sum_{j < i}^n a_{i,j} (\mathbf{x}^k)_j$ můžeme nahradit již známými prvky vektoru \mathbf{x}^{k+1}

$$(\mathbf{x}^{k+1})_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j < i}^n a_{i,j} (\mathbf{x}^{k+1})_j - \sum_{j > i}^n a_{i,j} (\mathbf{x}^k)_j \right)$$

- Maticový zápis můžeme opět snadno odvodit, rozdělíme-li $A = L + D + U$ a ponecháme-li u vektoru \mathbf{x}^{k+1} součet $(L + D)$

$$(L + D)\mathbf{x}^{k+1} = \mathbf{b} - U\mathbf{x}^k,$$

tedy

$$\mathbf{x}^{k+1} = \underbrace{-(L + D)^{-1}U}_{=M} \mathbf{x}^k + \underbrace{(L + D)^{-1}\mathbf{b}}_{=N}.$$

- Ověříme opět konzistenci (pomocí podmínky $M = I - NA$):

$$M = -(L + D)^{-1}U, \quad N = (L + D)^{-1}$$

$$I - NA =$$

- Ověříme opět konzistenci (pomocí podmínky $M = I - NA$):

$$M = -(L + D)^{-1}U, \quad N = (L + D)^{-1}$$

$$I - NA = I - (L + D)^{-1}A$$

- Ověříme opět konzistenci (pomocí podmínky $M = I - NA$):

$$M = -(L + D)^{-1}U, \quad N = (L + D)^{-1}$$

$$I - NA = I - (L + D)^{-1}A = I - (L + D)^{-1}(L + D + U)$$

- Ověříme opět konzistenci (pomocí podmínky $M = I - NA$):

$$M = -(L + D)^{-1}U, \quad N = (L + D)^{-1}$$

$$\begin{aligned} I - NA &= I - (L + D)^{-1}A = I - (L + D)^{-1}(L + D + U) \\ &= I - (L + D)^{-1}(L + D) - (L + D)^{-1}U \end{aligned}$$

- Ověříme opět konzistenci (pomocí podmínky $M = I - NA$):

$$M = -(L + D)^{-1}U, \quad N = (L + D)^{-1}$$

$$\begin{aligned} I - NA &= I - (L + D)^{-1}A = I - (L + D)^{-1}(L + D + U) \\ &= I - (L + D)^{-1}(L + D) - (L + D)^{-1}U = -(L + D)^{-1}U \end{aligned}$$

- Ověříme opět konzistenci (pomocí podmínky $M = I - NA$):

$$M = -(L + D)^{-1}U, \quad N = (L + D)^{-1}$$

$$\begin{aligned} I - NA &= I - (L + D)^{-1}A = I - (L + D)^{-1}(L + D + U) \\ &= I - (L + D)^{-1}(L + D) - (L + D)^{-1}U = -(L + D)^{-1}U = M \end{aligned}$$

- Ověříme opět konzistenci (pomocí podmínky $M = I - NA$):

$$M = -(L + D)^{-1}U, \quad N = (L + D)^{-1}$$

$$\begin{aligned} I - NA &= I - (L + D)^{-1}A = I - (L + D)^{-1}(L + D + U) \\ &= I - (L + D)^{-1}(L + D) - (L + D)^{-1}U = -(L + D)^{-1}U = M \end{aligned}$$

- Metoda je konvergentní, právě tehdy když $\|(L + D)^{-1}U\| < 1$, což opět platí pro diagonálně dominantní matice.

Richardsonova metoda

- Iterace Richardsonovy metody je dána předpisem

$$\boldsymbol{x}^{k+1} = \boldsymbol{x}^k + \omega \boldsymbol{r}^k,$$

kde $\omega \in \mathbb{R}_+$ a $\boldsymbol{r}^k = \boldsymbol{b} - A\boldsymbol{x}^k$ je reziduum, které určuje, jak dobře je splněna původní rovnice.

Richardsonova metoda

- Iterace Richardsonovy metody je dána předpisem

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \omega \mathbf{r}^k,$$

kde $\omega \in \mathbb{R}_+$ a $\mathbf{r}^k = \mathbf{b} - A\mathbf{x}^k$ je reziduum, které určuje, jak dobře je splněna původní rovnice.

- Metodu tedy můžeme zapsat také ve tvaru

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \omega(\mathbf{b} - A\mathbf{x}^k) = \underbrace{(I - \omega A)}_{=M} \mathbf{x}^k + \underbrace{\omega}_{=\omega I=N} \S \mathbf{b}$$

Richardsonova metoda

- Iterace Richardsonovy metody je dána předpisem

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \omega \mathbf{r}^k,$$

kde $\omega \in \mathbb{R}_+$ a $\mathbf{r}^k = \mathbf{b} - A\mathbf{x}^k$ je reziduum, které určuje, jak dobře je splněna původní rovnice.

- Metodu tedy můžeme zapsat také ve tvaru

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \omega(\mathbf{b} - A\mathbf{x}^k) = \underbrace{(I - \omega A)}_{=M} \mathbf{x}^k + \underbrace{\omega}_{=\omega I=N} \S \mathbf{b}$$

- Metoda je konzistentní pro všechna ω :

$$\mathbf{x} + \omega \underbrace{(\mathbf{b} - A\mathbf{x})}_{=o} = \mathbf{x}$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i = r^{k+1} =$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i = r^{k+1} = b - Ax^{k+1} =$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i = r^{k+1} = b - Ax^{k+1} = \underbrace{b - A(x^k + \omega r^k)}_{=r^k}$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\begin{aligned} \sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i &= r^{k+1} = b - Ax^{k+1} = \underbrace{b - A(x^k + \omega r^k)}_{=r^k} = \\ &= r^k - A\omega r^k = \end{aligned}$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\begin{aligned} \sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i &= r^{k+1} = b - Ax^{k+1} = \underbrace{b - A(x^k + \omega r^k)}_{=r^k} = \\ &= r^k - A\omega r^k = (I - \omega A) \underbrace{r^k}_{=\sum_{i=1}^n \alpha_i^k v_i} \end{aligned}$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze vytvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\begin{aligned} \sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i &= r^{k+1} = b - Ax^{k+1} = \underbrace{b - A(x^k + \omega r^k)}_{=r^k} = \\ &= r^k - A\omega r^k = (I - \omega A) \underbrace{r^k}_{=\sum_{i=1}^n \alpha_i^k v_i} = (I - \omega A) \sum_{i=1}^n \alpha_i^k v_i \end{aligned}$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze vytvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\begin{aligned} \sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i &= r^{k+1} = b - Ax^{k+1} = \underbrace{b - A(x^k + \omega r^k)}_{=r^k} = \\ &= r^k - A\omega r^k = (I - \omega A) \underbrace{r^k}_{=\sum_{i=1}^n \alpha_i^k v_i} = (I - \omega A) \sum_{i=1}^n \alpha_i^k v_i = \\ &= \sum_{i=1}^n \alpha_i^k v_i - \sum_{i=1}^n \alpha_i^k \omega \underbrace{Av_i}_{=\lambda_i v_i} \end{aligned}$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\begin{aligned} \sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i &= r^{k+1} = b - Ax^{k+1} = \underbrace{b - A(x^k + \omega r^k)}_{=r^k} = \\ &= r^k - A\omega r^k = (I - \omega A) \underbrace{r^k}_{=\sum_{i=1}^n \alpha_i^k v_i} = (I - \omega A) \sum_{i=1}^n \alpha_i^k v_i = \\ &= \sum_{i=1}^n \alpha_i^k v_i - \sum_{i=1}^n \alpha_i^k \omega \underbrace{Av_i}_{=\lambda_i v_i} = \sum_{i=1}^n \alpha_i^k v_i - \sum_{i=1}^n \alpha_i^k \omega \lambda_i v_i \end{aligned}$$

- Vztah mezi reziduem a chybou $e^k = x^k - x$ lze odvodit přenásobením definice chyby maticí A

$$Ae^k = Ax^k - Ax = Ax^k - b = -r^k.$$

- Studujme konvergenci metody pro symetrickou pozitivně definitní matici A . V takovém případě vlastní čísla λ_i a vlastní vektory v_i (tedy skaláry a vektory, pro které platí $Av_i = \lambda_i v_i$, $\|v\| = 1$) splňují

$$0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

a z vlastních vektorů lze utvořit ortonormální bázi \mathbb{R}^n .

- Reziduum v kroku k si můžeme vyjádřit jako $r^k = \sum_{i=1}^n \alpha_i^k v_i$.

$$\begin{aligned} \sum_{i=1}^n \underline{\alpha_i^{k+1}} v_i &= r^{k+1} = b - Ax^{k+1} = \underbrace{b - A(x^k + \omega r^k)}_{=r^k} = \\ &= r^k - A\omega r^k = (I - \omega A) \underbrace{r^k}_{=\sum_{i=1}^n \alpha_i^k v_i} = (I - \omega A) \sum_{i=1}^n \alpha_i^k v_i = \\ &= \sum_{i=1}^n \alpha_i^k v_i - \sum_{i=1}^n \alpha_i^k \omega \underbrace{Av_i}_{=\lambda_i v_i} = \sum_{i=1}^n \alpha_i^k v_i - \sum_{i=1}^n \alpha_i^k \omega \lambda_i v_i = \\ &= \sum_{i=1}^n \underline{(1 - \omega \lambda_i) \alpha_i^k} v_i. \end{aligned}$$

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i \Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2.$$

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\begin{aligned} \mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i &\Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2. \\ \Rightarrow \|\mathbf{r}^{k+1}\|^2 &= \sum_i [(1 - \omega \lambda_i) \alpha_i^k]^2 \end{aligned}$$

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i \Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2.$$

$$\Rightarrow \|\mathbf{r}^{k+1}\|^2 = \sum_i [(1 - \omega \lambda_i) \alpha_i^k]^2 \leq \sum_i [\max_j |1 - \omega \lambda_j| \alpha_i^k]^2$$

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i \Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2.$$

$$\begin{aligned} \Rightarrow \|\mathbf{r}^{k+1}\|^2 &= \sum_i [(1 - \omega \lambda_i) \alpha_i^k]^2 \leq \sum_i [\max_j |1 - \omega \lambda_j| \alpha_i^k]^2 = \\ &= (\max_j |1 - \omega \lambda_j|)^2 \sum_i |(\alpha_i^k)|^2 \end{aligned}$$

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i \Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2.$$

$$\begin{aligned} \Rightarrow \|\mathbf{r}^{k+1}\|^2 &= \sum_i [(1 - \omega \lambda_i) \alpha_i^k]^2 \leq \sum_i [\max_j |1 - \omega \lambda_j| \alpha_i^k]^2 = \\ &= (\max_j |1 - \omega \lambda_j|)^2 \sum_i |(\alpha_i^k)|^2 = \rho^2 \|\mathbf{r}^k\|^2 \end{aligned}$$

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i \Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2.$$

$$\begin{aligned} \Rightarrow \|\mathbf{r}^{k+1}\|^2 &= \sum_i [(1 - \omega \lambda_i) \alpha_i^k]^2 \leq \sum_i [\max_j |1 - \omega \lambda_j| \alpha_i^k]^2 = \\ &= (\max_j |1 - \omega \lambda_j|)^2 \sum_i |(\alpha_i^k)|^2 = \rho^2 \|\mathbf{r}^k\|^2 \end{aligned}$$

- Tedy $\|\mathbf{r}^{k+1}\| \leq \rho \|\mathbf{r}^k\|$, kde $\rho = \max_{i \in \{1, \dots, n\}} |1 - \omega \lambda_i|$ nazýváme *konvergenčním faktorem*.

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i \Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2.$$

$$\begin{aligned} \Rightarrow \|\mathbf{r}^{k+1}\|^2 &= \sum_i [(1 - \omega \lambda_i) \alpha_i^k]^2 \leq \sum_i [\max_j |1 - \omega \lambda_j| \alpha_i^k]^2 = \\ &= (\max_j |1 - \omega \lambda_j|)^2 \sum_i |(\alpha_i^k)|^2 = \rho^2 \|\mathbf{r}^k\|^2 \end{aligned}$$

- Tedy $\|\mathbf{r}^{k+1}\| \leq \rho \|\mathbf{r}^k\|$, kde $\rho = \max_{i \in \{1, \dots, n\}} |1 - \omega \lambda_i|$ nazýváme *konvergenčním faktorem*. Odtud

$$\|\mathbf{r}^k\| \leq \rho \underbrace{\|\mathbf{r}^{k-1}\|}_{\leq \rho \|\mathbf{r}^{k-2}\|}$$

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i \Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2.$$

$$\begin{aligned} \Rightarrow \|\mathbf{r}^{k+1}\|^2 &= \sum_i [(1 - \omega \lambda_i) \alpha_i^k]^2 \leq \sum_i [\max_j |1 - \omega \lambda_j| \alpha_i^k]^2 = \\ &= (\max_j |1 - \omega \lambda_j|)^2 \sum_i |(\alpha_i^k)|^2 = \rho^2 \|\mathbf{r}^k\|^2 \end{aligned}$$

- Tedy $\|\mathbf{r}^{k+1}\| \leq \rho \|\mathbf{r}^k\|$, kde $\rho = \max_{i \in \{1, \dots, n\}} |1 - \omega \lambda_i|$ nazýváme *konvergenčním faktorem*. Odtud

$$\|\mathbf{r}^k\| \leq \rho \underbrace{\|\mathbf{r}^{k-1}\|}_{\leq \rho \|\mathbf{r}^{k-2}\|} \leq \rho^2 \|\mathbf{r}^{k-2}\|$$

- Richardsonova metoda tedy konverguje právě tehdy, když $\forall i = 1, \dots, n: |1 - \omega \lambda_i| < 1$.
- Můžeme určit, jak rychle metoda konverguje pro dané ω :

$$\mathbf{u} = \sum_1^n \alpha_i \mathbf{v}_i \Rightarrow \|\mathbf{u}\|^2 = \mathbf{u}^T \mathbf{u} = \sum_j \alpha_j \mathbf{v}_j^T \sum_i \alpha_i \mathbf{v}_i = \sum_j \sum_i \alpha_j \alpha_i \mathbf{v}_j^T \mathbf{v}_i = \sum_i \alpha_i^2.$$

$$\begin{aligned} \Rightarrow \|\mathbf{r}^{k+1}\|^2 &= \sum_i [(1 - \omega \lambda_i) \alpha_i^k]^2 \leq \sum_i [\max_j |1 - \omega \lambda_j| \alpha_i^k]^2 = \\ &= (\max_j |1 - \omega \lambda_j|)^2 \sum_i |(\alpha_i^k)|^2 = \rho^2 \|\mathbf{r}^k\|^2 \end{aligned}$$

- Tedy $\|\mathbf{r}^{k+1}\| \leq \rho \|\mathbf{r}^k\|$, kde $\rho = \max_{i \in \{1, \dots, n\}} |1 - \omega \lambda_i|$ nazýváme *konvergenčním faktorem*. Odtud


$$\|\mathbf{r}^k\| \leq \rho \underbrace{\|\mathbf{r}^{k-1}\|}_{\leq \rho \|\mathbf{r}^{k-2}\|} \leq \rho^2 \|\mathbf{r}^{k-2}\| \leq \dots \leq \rho^k \|\mathbf{r}^0\|$$

- Jak zvolit ω , aby konvergenční faktor byl co nejlepší (nejmenší)?




- Jak zvolit ω , aby konvergenční faktor byl co nejlepší (nejmenší)?

$$f_i(\omega) = |1 - \omega \lambda_i|$$




- Jak zvolit ω , aby konvergenční faktor byl co nejlepší (nejmenší)?

$$f_i(\omega) = |1 - \omega \lambda_i|$$




- Jak zvolit ω , aby konvergenční faktor byl co nejlepší (nejmenší)?



$$f_i(\omega) = |1 - \omega\lambda_i|$$

$$1 - \omega\lambda_i = 0 \Rightarrow \omega = \frac{1}{\lambda_i}$$


- Jak zvolit ω , aby konvergenční faktor byl co nejlepší (nejmenší)?



$$f_i(\omega) = |1 - \omega \lambda_i|$$

$$1 - \omega \lambda_i = 0 \Rightarrow \omega = \frac{1}{\lambda_i}$$

- Jak zvolit ω , aby konvergenční faktor byl co nejlepší (nejmenší)?




$$f_i(\omega) = |1 - \omega \lambda_i|$$

$$1 - \omega \lambda_i = 0 \Rightarrow \omega = \frac{1}{\lambda_i}$$

Aby metoda konvergovala, musí být $\max_{i \in \{1, \dots, n\}} |1 - \omega \lambda_i| < 1$.

$$-1 + \omega \lambda_n = 1 \Rightarrow \omega = \frac{2}{\lambda_n}$$

- Jak zvolit ω , aby konvergenční faktor byl co nejlepší (nejmenší)?



$$f_i(\omega) = |1 - \omega \lambda_i|$$


$$1 - \omega \lambda_i = 0 \Rightarrow \omega = \frac{1}{\lambda_i}$$

Aby metoda konvergovala, musí být $\max_{i \in \{1, \dots, n\}} |1 - \omega \lambda_i| < 1$.

$$-1 + \omega \lambda_n = 1 \Rightarrow \omega = \frac{2}{\lambda_n}$$

Metoda konverguje pro $\omega \in (0, 2/\lambda_n)$.

- Jak zvolit ω , aby konvergenční faktor byl co nejlepší (nejmenší)?



$$f_i(\omega) = |1 - \omega \lambda_i|$$

$$1 - \omega \lambda_i = 0 \Rightarrow \omega = \frac{1}{\lambda_i}$$

Aby metoda konvergovala, musí být $\max_{i \in \{1, \dots, n\}} |1 - \omega \lambda_i| < 1$.

$$-1 + \omega \lambda_n = 1 \Rightarrow \omega = \frac{2}{\lambda_n}$$

Metoda konverguje pro $\omega \in (0, 2/\lambda_n)$.
Optimální konvergence je dosaženo v ω_{opt} :

$$1 - \omega_{\text{opt}} \lambda_1 = -(1 - \omega_{\text{opt}} \lambda_n)$$

$$\Rightarrow \omega_{\text{opt}} = \frac{2}{\lambda_1 + \lambda_n}$$

Zjistili jsme tedy, že nejlepší konvergence dosáhneme, zvolíme-li $\omega_{\text{opt}} = \frac{2}{\lambda_1 + \lambda_n}$. Konvergenční faktor bude v tomto případě

$$\begin{aligned}\rho_{\text{opt}} &= 1 - \omega_{\text{opt}}\lambda_1 = 1 - \frac{2\lambda_1}{\lambda_1 + \lambda_n} = \frac{\lambda_1 + \lambda_n - 2\lambda_1}{\lambda_1 + \lambda_n} = \\ &= \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \frac{\frac{1}{\lambda_1}}{\frac{1}{\lambda_1}} = \frac{\frac{\lambda_n}{\lambda_1} - 1}{\frac{\lambda_n}{\lambda_1} + 1} = \frac{\kappa(\mathbf{A}) - 1}{\kappa(\mathbf{A}) + 1},\end{aligned}$$

kde $\kappa(\mathbf{A}) = \lambda_n/\lambda_1$ je číslo podmíněnosti matice \mathbf{A} .

Ukončovací podmínky

Bud' x^0 počáteční odhad řešení,

$$x^{k+1} = Mx^k + Nb.$$

- Kdy iterování ukončit?

Ukončovací podmínky

Bud' x^0 počáteční odhad řešení,

$$x^{k+1} = Mx^k + Nb.$$

- Kdy iterování ukončit?

- 1 Po dosažení určitého počtu iterací – neřekne nám většinou nic o tom, jak blízko jsme řešení. Používá se spíše jako dodatečná podmínka pro případ, že by metoda nekonvergovala.

Ukončovací podmínky

Bud' \mathbf{x}^0 počáteční odhad řešení,

$$\mathbf{x}^{k+1} = \mathbf{M}\mathbf{x}^k + \mathbf{N}\mathbf{b}.$$

■ Kdy iterování ukončit?

- 1 Po dosažení určitého počtu iterací – neřekne nám většinou nic o tom, jak blízko jsme řešení. Používá se spíše jako dodatečná podmínka pro případ, že by metoda nekonvergovala.
- 2 Když se s novým odhadem řešení příliš nevzdálíme od předchozího odhadu (tzn. $\|\mathbf{x}^{k+1} - \mathbf{x}^k\| < \varepsilon$). Takto formulovaná podmínka nebere v potaz velikost prvků vektorů, proto je lepší zvolit ji relativně např. vzhledem k normě vektoru pravé strany:
 $\|\mathbf{x}^{k+1} - \mathbf{x}^k\| < \|\mathbf{b}\|\varepsilon$, tedy $\|\mathbf{x}^{k+1} - \mathbf{x}^k\|/\|\mathbf{b}\| < \varepsilon$.

Ukončovací podmínky

Bud' \mathbf{x}^0 počáteční odhad řešení,

$$\mathbf{x}^{k+1} = \mathbf{M}\mathbf{x}^k + \mathbf{N}\mathbf{b}.$$

■ Kdy iterování ukončit?

- 1 Po dosažení určitého počtu iterací – neřekne nám většinou nic o tom, jak blízko jsme řešení. Používá se spíše jako dodatečná podmínka pro případ, že by metoda nekonvergovala.
- 2 Když se s novým odhadem řešení příliš nevzdálíme od předchozího odhadu (tzn. $\|\mathbf{x}^{k+1} - \mathbf{x}^k\| < \varepsilon$). Takto formulovaná podmínka nebere v potaz velikost prvků vektorů, proto je lepší zvolit ji relativně např. vzhledem k normě vektoru pravé strany: $\|\mathbf{x}^{k+1} - \mathbf{x}^k\| < \|\mathbf{b}\|\varepsilon$, tedy $\|\mathbf{x}^{k+1} - \mathbf{x}^k\|/\|\mathbf{b}\| < \varepsilon$.
- 3 Nejčastěji se používá normy vektoru rezidua $\mathbf{r}^{k+1} = \mathbf{b} - \mathbf{A}\mathbf{x}^{k+1}$, tedy $\|\mathbf{b} - \mathbf{A}\mathbf{x}^{k+1}\| < \varepsilon$. Vhodnější je opět použít relativní změnu rezidua oproti vektoru pravé strany ($\|\mathbf{b} - \mathbf{A}\mathbf{x}^{k+1}\|/\|\mathbf{b}\| < \varepsilon$) nebo počátečnímu reziduu ($\|\mathbf{b} - \mathbf{A}\mathbf{x}^{k+1}\|/\|\mathbf{b} - \mathbf{A}\mathbf{x}^0\| < \varepsilon$).

- Algoritmus Richardsonovy metody pak vypadá např. takto:

function Richardson($A, \mathbf{b}, \mathbf{x}^0, \omega, \varepsilon$)

$$\mathbf{r}^0 = \mathbf{b} - A\mathbf{x}^0$$

$$k = 0$$

while $\|\mathbf{r}^k\|/\|\mathbf{r}^0\| > \varepsilon$ & $k < 100$ **do**

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \omega \mathbf{r}^k$$

$$\mathbf{r}^{k+1} = \mathbf{b} - A\mathbf{x}^k$$

$$k = k + 1$$

end while

end function

- V případě Richardsonovy metody můžeme předem odhadnout potřebný počet iterací pro dosažení relativní přesnosti $\|\mathbf{r}^k\| \leq \varepsilon \|\mathbf{r}^0\|$:

- V případě Richardsonovy metody můžeme předem odhadnout potřebný počet iterací pro dosažení relativní přesnosti $\|\mathbf{r}^k\| \leq \varepsilon \|\mathbf{r}^0\|$:

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \varepsilon$$

- V případě Richardsonovy metody můžeme předem odhadnout potřebný počet iterací pro dosažení relativní přesnosti $\|\mathbf{r}^k\| \leq \varepsilon \|\mathbf{r}^0\|$:

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \varepsilon$$

$$\|\mathbf{r}^k\| \leq \rho^k \|\mathbf{r}^0\|$$

- V případě Richardsonovy metody můžeme předem odhadnout potřebný počet iterací pro dosažení relativní přesnosti $\|\mathbf{r}^k\| \leq \varepsilon \|\mathbf{r}^0\|$:

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \varepsilon$$

$$\|\mathbf{r}^k\| \leq \rho^k \|\mathbf{r}^0\|$$

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \rho^k$$

- V případě Richardsonovy metody můžeme předem odhadnout potřebný počet iterací pro dosažení relativní přesnosti $\|\mathbf{r}^k\| \leq \varepsilon \|\mathbf{r}^0\|$:

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \varepsilon$$

$$\|\mathbf{r}^k\| \leq \rho^k \|\mathbf{r}^0\|$$

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \rho^k \leq \varepsilon$$

- V případě Richardsonovy metody můžeme předem odhadnout potřebný počet iterací pro dosažení relativní přesnosti $\|\mathbf{r}^k\| \leq \varepsilon \|\mathbf{r}^0\|$:

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \varepsilon$$

$$\|\mathbf{r}^k\| \leq \rho^k \|\mathbf{r}^0\|$$

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \rho^k \leq \varepsilon$$

$$\log \rho^k \leq \log \varepsilon$$

- V případě Richardsonovy metody můžeme předem odhadnout potřebný počet iterací pro dosažení relativní přesnosti $\|\mathbf{r}^k\| \leq \varepsilon \|\mathbf{r}^0\|$:

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \varepsilon$$

$$\|\mathbf{r}^k\| \leq \rho^k \|\mathbf{r}^0\|$$

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \rho^k \leq \varepsilon$$

$$\log \rho^k \leq \log \varepsilon$$

$$k \log \rho \leq \log \varepsilon$$

- V případě Richardsonovy metody můžeme předem odhadnout potřebný počet iterací pro dosažení relativní přesnosti $\|\mathbf{r}^k\| \leq \varepsilon \|\mathbf{r}^0\|$:

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \varepsilon$$

$$\|\mathbf{r}^k\| \leq \rho^k \|\mathbf{r}^0\|$$

$$\frac{\|\mathbf{r}^k\|}{\|\mathbf{r}^0\|} \leq \rho^k \leq \varepsilon$$

$$\log \rho^k \leq \log \varepsilon$$

$$k \log \rho \leq \log \varepsilon$$

$$k \geq \frac{\log \varepsilon}{\log \rho}$$

Děkuji za pozornost

Michal Merta

VŠB – Technická univerzita Ostrava

michal.merta@vsb.cz

30. března 2023