

Numerická lineární algebra 1

Řešení soustav lineárních rovnic - iterační metody (metoda největšího spádu, metoda sdružených gradientů, předpodmínění)

Michal Merta

VŠB – Technická univerzita Ostrava

michal.merta@vsb.cz

6. dubna 2023

1 Gradientní iterační metody

2 Předpokládání

Geometrická interpretace řešení soustav lineárních rovnic

■ Řešení soustavy

$$a_{1,1}x_1 + \dots + a_{1,n}x_n = b_1$$

$$\vdots$$

$$a_{n,1}x_1 + \dots + a_{n,n}x_n = b_n$$

lze interpretovat jako hledání průsečíku n nadrovin v \mathbb{R}^n .

Geometrická interpretace řešení soustav lineárních rovnic

■ Řešení soustavy

$$a_{1,1}x_1 + \dots + a_{1,n}x_n = b_1$$

$$\vdots$$


$$a_{n,1}x_1 + \dots + a_{n,n}x_n = b_n$$

lze interpretovat jako hledání průsečíku n nadrovin v \mathbb{R}^n .

■ Např.

$$3x_1 + 2x_2 = 2$$

$$2x_1 + 6x_2 = -8$$



- Pokud je matice soustavy symetrická pozitivně definitní, můžeme řešení interpretovat jiným způsobem.

Věta

Řešení soustavy $Ax = b$ se symetrickou pozitivně definitní maticí A je ekvivalentní s minimalizací kvadratické formy $f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$f(x) = \frac{1}{2}x^T Ax - b^T x.$$

Dk.

$$1 \quad A\mathbf{x} = \mathbf{b} \Rightarrow \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v})$$

$$f(\mathbf{p}) = f(\mathbf{x} + \mathbf{c})$$

Dk.

$$1 \quad A\mathbf{x} = \mathbf{b} \Rightarrow \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v})$$

$$f(\mathbf{p}) = f(\mathbf{x} + \mathbf{c}) = \frac{1}{2}(\mathbf{x} + \mathbf{c})^T A(\mathbf{x} + \mathbf{c}) - \mathbf{b}^T(\mathbf{x} + \mathbf{c})$$

Dk.

$$1 \quad Ax = b \Rightarrow x = \arg \min_{v \in \mathbb{R}^n} f(v)$$

$$\begin{aligned} f(p) &= f(x + c) = \frac{1}{2}(x + c)^T A(x + c) - b^T(x + c) = \\ &= \frac{1}{2}x^T Ax + \underbrace{c^T Ax}_{=b} + \frac{1}{2}c^T Ac - b^T x - b^T c \end{aligned}$$

Dk.

$$1 \quad Ax = b \Rightarrow x = \arg \min_{v \in \mathbb{R}^n} f(v)$$

$$\begin{aligned} f(p) &= f(x + c) = \frac{1}{2}(x + c)^T A(x + c) - b^T(x + c) = \\ &= \frac{1}{2}x^T Ax + \underbrace{c^T Ax}_{=b} + \frac{1}{2}c^T Ac - b^T x - b^T c = \\ &= \underbrace{\frac{1}{2}x^T Ax - b^T x}_{=f(x)} + \underbrace{c^T b - b^T c}_{=0} + \frac{1}{2}c^T Ac \end{aligned}$$

Dk.

$$1 \quad \mathbf{Ax} = \mathbf{b} \Rightarrow \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v})$$

$$\begin{aligned} f(\mathbf{p}) &= f(\mathbf{x} + \mathbf{c}) = \frac{1}{2}(\mathbf{x} + \mathbf{c})^T \mathbf{A}(\mathbf{x} + \mathbf{c}) - \mathbf{b}^T(\mathbf{x} + \mathbf{c}) = \\ &= \frac{1}{2}\mathbf{x}^T \mathbf{A}\mathbf{x} + \underbrace{\mathbf{c}^T \mathbf{A}\mathbf{x}}_{=\mathbf{b}} + \frac{1}{2}\mathbf{c}^T \mathbf{A}\mathbf{c} - \mathbf{b}^T \mathbf{x} - \mathbf{b}^T \mathbf{c} = \\ &= \underbrace{\frac{1}{2}\mathbf{x}^T \mathbf{A}\mathbf{x} - \mathbf{b}^T \mathbf{x}}_{=f(\mathbf{x})} + \underbrace{\mathbf{c}^T \mathbf{b} - \mathbf{b}^T \mathbf{c}}_{=0} + \frac{1}{2}\mathbf{c}^T \mathbf{A}\mathbf{c} = f(\mathbf{x}) + \underbrace{\frac{1}{2}\mathbf{c}^T \mathbf{A}\mathbf{c}}_{>0}. \end{aligned}$$

Dk.

$$1 \quad \mathbf{Ax} = \mathbf{b} \Rightarrow \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v})$$

$$\begin{aligned} f(\mathbf{p}) &= f(\mathbf{x} + \mathbf{c}) = \frac{1}{2}(\mathbf{x} + \mathbf{c})^T \mathbf{A}(\mathbf{x} + \mathbf{c}) - \mathbf{b}^T(\mathbf{x} + \mathbf{c}) = \\ &= \frac{1}{2}\mathbf{x}^T \mathbf{A}\mathbf{x} + \underbrace{\mathbf{c}^T \mathbf{A}\mathbf{x}}_{=\mathbf{b}} + \frac{1}{2}\mathbf{c}^T \mathbf{A}\mathbf{c} - \mathbf{b}^T \mathbf{x} - \mathbf{b}^T \mathbf{c} = \\ &= \underbrace{\frac{1}{2}\mathbf{x}^T \mathbf{A}\mathbf{x} - \mathbf{b}^T \mathbf{x}}_{=f(\mathbf{x})} + \underbrace{\mathbf{c}^T \mathbf{b} - \mathbf{b}^T \mathbf{c}}_{=0} + \frac{1}{2}\mathbf{c}^T \mathbf{A}\mathbf{c} = f(\mathbf{x}) + \underbrace{\frac{1}{2}\mathbf{c}^T \mathbf{A}\mathbf{c}}_{>0}. \end{aligned}$$

$$2 \quad \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v}) \Rightarrow \mathbf{Ax} = \mathbf{b}$$

Využijeme nutnou podmínku minima $f: \mathbb{R}^n \rightarrow \mathbb{R}$, tedy nulovost gradientu.

Dk.

$$1 \quad A\mathbf{x} = \mathbf{b} \Rightarrow \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v})$$

$$\begin{aligned} f(\mathbf{p}) &= f(\mathbf{x} + \mathbf{c}) = \frac{1}{2}(\mathbf{x} + \mathbf{c})^T A(\mathbf{x} + \mathbf{c}) - \mathbf{b}^T(\mathbf{x} + \mathbf{c}) = \\ &= \frac{1}{2}\mathbf{x}^T A\mathbf{x} + \underbrace{\mathbf{c}^T A\mathbf{x}}_{=\mathbf{b}} + \frac{1}{2}\mathbf{c}^T A\mathbf{c} - \mathbf{b}^T \mathbf{x} - \mathbf{b}^T \mathbf{c} = \\ &= \underbrace{\frac{1}{2}\mathbf{x}^T A\mathbf{x} - \mathbf{b}^T \mathbf{x}}_{=f(\mathbf{x})} + \underbrace{\mathbf{c}^T \mathbf{b} - \mathbf{b}^T \mathbf{c}}_{=0} + \frac{1}{2}\mathbf{c}^T A\mathbf{c} = f(\mathbf{x}) + \underbrace{\frac{1}{2}\mathbf{c}^T A\mathbf{c}}_{>0}. \end{aligned}$$

$$2 \quad \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v}) \Rightarrow A\mathbf{x} = \mathbf{b}$$

Využijeme nutnou podmínku minima $f: \mathbb{R}^n \rightarrow \mathbb{R}$, tedy nulovost gradientu.

$$\mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v}) \Rightarrow \nabla f(\mathbf{x}) = \mathbf{0}.$$

Dk.

$$1 \quad \mathbf{Ax} = \mathbf{b} \Rightarrow \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v})$$

$$\begin{aligned} f(\mathbf{p}) &= f(\mathbf{x} + \mathbf{c}) = \frac{1}{2}(\mathbf{x} + \mathbf{c})^T \mathbf{A}(\mathbf{x} + \mathbf{c}) - \mathbf{b}^T(\mathbf{x} + \mathbf{c}) = \\ &= \frac{1}{2}\mathbf{x}^T \mathbf{Ax} + \underbrace{\mathbf{c}^T \mathbf{Ax}}_{=\mathbf{b}} + \frac{1}{2}\mathbf{c}^T \mathbf{Ac} - \mathbf{b}^T \mathbf{x} - \mathbf{b}^T \mathbf{c} = \\ &= \underbrace{\frac{1}{2}\mathbf{x}^T \mathbf{Ax} - \mathbf{b}^T \mathbf{x}}_{=f(\mathbf{x})} + \underbrace{\mathbf{c}^T \mathbf{b} - \mathbf{b}^T \mathbf{c}}_{=0} + \frac{1}{2}\mathbf{c}^T \mathbf{Ac} = f(\mathbf{x}) + \underbrace{\frac{1}{2}\mathbf{c}^T \mathbf{Ac}}_{>0}. \end{aligned}$$

$$2 \quad \mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v}) \Rightarrow \mathbf{Ax} = \mathbf{b}$$

Využijeme nutnou podmínku minima $f: \mathbb{R}^n \rightarrow \mathbb{R}$, tedy nulovost gradientu.

$$\mathbf{x} = \arg \min_{\mathbf{v} \in \mathbb{R}^n} f(\mathbf{v}) \Rightarrow \nabla f(\mathbf{x}) = \mathbf{0}.$$

$$\nabla f(\mathbf{x}) = \left[\frac{\partial f}{\partial x_1}(\mathbf{x}), \dots, \frac{\partial f}{\partial x_n}(\mathbf{x}) \right]^T = \frac{1}{2}\mathbf{A}^T \mathbf{x} + \frac{1}{2}\mathbf{Ax} - \mathbf{b} = \mathbf{Ax} - \mathbf{b}.$$

Dk.

$$1 \quad Ax = b \Rightarrow x = \arg \min_{v \in \mathbb{R}^n} f(v)$$

$$\begin{aligned} f(p) &= f(x + c) = \frac{1}{2}(x + c)^T A(x + c) - b^T(x + c) = \\ &= \frac{1}{2}x^T Ax + \underbrace{c^T Ax}_{=b} + \frac{1}{2}c^T Ac - b^T x - b^T c = \\ &= \underbrace{\frac{1}{2}x^T Ax - b^T x}_{=f(x)} + \underbrace{c^T b - b^T c}_{=0} + \frac{1}{2}c^T Ac = f(x) + \underbrace{\frac{1}{2}c^T Ac}_{>0}. \end{aligned}$$

$$2 \quad x = \arg \min_{v \in \mathbb{R}^n} f(v) \Rightarrow Ax = b$$

Využijeme nutnou podmínku minima $f: \mathbb{R}^n \rightarrow \mathbb{R}$, tedy nulovost gradientu.

$$x = \arg \min_{v \in \mathbb{R}^n} f(v) \Rightarrow \nabla f(x) = o.$$

$$\nabla f(x) = \left[\frac{\partial f}{\partial x_1}(x), \dots, \frac{\partial f}{\partial x_n}(x) \right]^T = \frac{1}{2}A^T x + \frac{1}{2}Ax - b = Ax - b.$$

Tedy $Ax - b = o$.

□

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$

$$f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$

$$f(\mathbf{x}) = f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{Ax} - \mathbf{b}^T \mathbf{x}$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$

$$f(\mathbf{x}) = f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{Ax} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} =$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{Ax} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} = \frac{1}{2} \left(2a_{1,1} x_1 \right.$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{Ax} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} = \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i} x_i \right)$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{Ax} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} = \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i}x_i + x_2a_{2,1} + \dots + x_na_{n,1} \right)$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{Ax} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} = \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i}x_i + x_2a_{2,1} + \dots + x_na_{n,1} \right) - b_1$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{Ax} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\begin{aligned} \frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} &= \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i} x_i + x_2 a_{2,1} + \dots + x_n a_{n,1} \right) - b_1 \\ &= \frac{1}{2} \left(2a_{1,1}x_1 \right. \end{aligned}$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\begin{aligned} \frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} &= \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i}x_i + x_2a_{2,1} + \dots + x_na_{n,1} \right) - b_1 \\ &= \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i}x_i \right. \end{aligned}$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\begin{aligned} \frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} &= \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i}x_i + x_2a_{2,1} + \dots + x_na_{n,1} \right) - b_1 \\ &= \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i}x_i + \sum_{i=1, i \neq 1}^n a_{i,1}x_i \right) - b_1 \end{aligned}$$

- Ukažme, že $\nabla f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2, \dots, x_n) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} = \frac{1}{2} \mathbf{x}^T \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \sum_{i=1}^n b_i x_i \\ &= \frac{1}{2} \left(x_1 \sum_{i=1}^n a_{1,i} x_i + x_2 \sum_{i=1}^n a_{2,i} x_i + \dots + x_n \sum_{i=1}^n a_{n,i} x_i \right) - \sum_{i=1}^n b_i x_i \end{aligned}$$

- Gradient je vektor parciálních derivací. Vypočtěme tedy:

$$\begin{aligned} \frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} &= \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i}x_i + x_2a_{2,1} + \dots + x_na_{n,1} \right) - b_1 \\ &= \frac{1}{2} \left(2a_{1,1}x_1 + \sum_{i=1, i \neq 1}^n a_{1,i}x_i + \sum_{i=1, i \neq 1}^n a_{i,1}x_i \right) - b_1 = \frac{1}{2} \left(\sum_{i=1}^n a_{1,i}x_i + \sum_{i=1}^n a_{i,1}x_i \right) - b_1 \end{aligned}$$

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} = \frac{1}{2} \left(\sum_{i=1}^n a_{1,i} x_i + \sum_{i=1}^n a_{i,1} x_i \right) - b_1$$

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} = \frac{1}{2} \left(\sum_{i=1}^n a_{1,i} x_i + \sum_{i=1}^n a_{i,1} x_i \right) - b_1 = \frac{1}{2} \left(2 \sum_{i=1}^n a_{1,i} x_i \right) - b_1$$

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} = \frac{1}{2} \left(\sum_{i=1}^n a_{1,i} x_i + \sum_{i=1}^n a_{i,1} x_i \right) - b_1 = \frac{1}{2} \left(2 \sum_{i=1}^n a_{1,i} x_i \right) - b_1$$

■ Obecně

$$\frac{\partial f(\mathbf{x})}{\partial x_j} = \sum_{i=1}^n a_{j,i} x_i - b_j$$

$$\frac{\partial f(x_1, x_2, \dots, x_n)}{\partial x_1} = \frac{1}{2} \left(\sum_{i=1}^n a_{1,i} x_i + \sum_{i=1}^n a_{i,1} x_i \right) - b_1 = \frac{1}{2} \left(2 \sum_{i=1}^n a_{1,i} x_i \right) - b_1$$

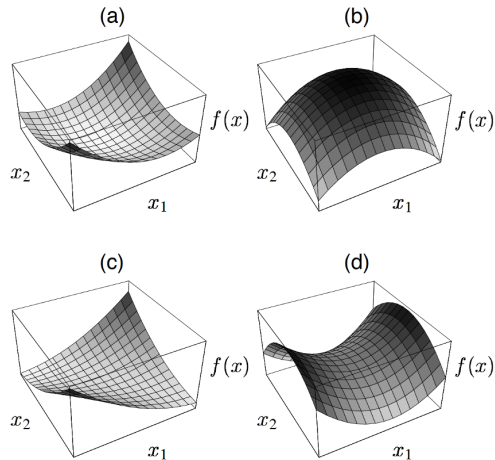
■ Obecně

$$\frac{\partial f(\mathbf{x})}{\partial x_j} = \sum_{i=1}^n a_{j,i} x_i - b_j$$

■ tedy

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f(\mathbf{x})}{\partial x_1} \\ \frac{\partial f(\mathbf{x})}{\partial x_2} \\ \vdots \\ \frac{\partial f(\mathbf{x})}{\partial x_n} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n a_{1,i} x_i \\ \sum_{i=1}^n a_{2,i} x_i \\ \vdots \\ \sum_{i=1}^n a_{n,i} x_i \end{bmatrix} - \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} = \mathbf{A}\mathbf{x} - \mathbf{b}$$

- V případě soustavy se symetrickou pozitivně definitní maticí můžeme řešení interpretovat jako hledání minima pozitivně definitní kvadratické formy.



Metoda největšího spádu

- Metoda největšího spádu je iterační metoda s předpisem

$$\boldsymbol{x}^{k+1} = \boldsymbol{x}^k + \alpha_k \boldsymbol{v}^k.$$

Metoda největšího spádu

- Metoda největšího spádu je iterační metoda s předpisem

$$\boldsymbol{x}^{k+1} = \boldsymbol{x}^k + \alpha_k \boldsymbol{v}^k.$$

- Směr \boldsymbol{v}^k volíme jako směr největšího poklesu funkce f .

Metoda největšího spádu

- Metoda největšího spádu je iterační metoda s předpisem

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{v}^k.$$

- Směr \mathbf{v}^k volíme jako směr největšího poklesu funkce f .
- Pro gradient (směr největšího růstu) funkce f platí

$$\nabla f(\mathbf{x}^k) = \mathbf{A}\mathbf{x}^k - \mathbf{b} = -(\mathbf{b} - \mathbf{A}\mathbf{x}^k) = -\mathbf{r}^k.$$

Metoda největšího spádu

- Metoda největšího spádu je iterační metoda s předpisem

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{v}^k.$$

- Směr \mathbf{v}^k volíme jako směr největšího poklesu funkce f .
- Pro gradient (směr největšího růstu) funkce f platí

$$\nabla f(\mathbf{x}^k) = A\mathbf{x}^k - \mathbf{b} = -(\mathbf{b} - A\mathbf{x}^k) = -\mathbf{r}^k.$$

- Směr \mathbf{v}^k zvolíme opačný ke gradientu, tzn. směr největšího poklesu:

$$\mathbf{v}^k = -\nabla f(\mathbf{x}^k) = \mathbf{r}^k.$$


- Délku kroku α_k zvolíme tak, abychom dosáhli minima f ve směru rezidua \boldsymbol{r}^k .

- Délku kroku α_k zvolíme tak, abychom dosáhli minima f ve směru rezidua \mathbf{r}^k .
- Definujme pomocnou funkci $F: \mathbb{R} \rightarrow \mathbb{R}$


$$\begin{aligned} F(\alpha) &= f(\mathbf{x}^k + \alpha \mathbf{r}^k) = \frac{1}{2}(\mathbf{x}^k + \alpha \mathbf{r}^k)^T \mathbf{A}(\mathbf{x}^k + \alpha \mathbf{r}^k) - \mathbf{b}^T(\mathbf{x}^k + \alpha \mathbf{r}^k) = \\ &= \frac{1}{2}(\mathbf{x}^k)^T \mathbf{A} \mathbf{x}^k + \alpha(\mathbf{x}^k)^T \mathbf{A} \mathbf{r}^k + \frac{1}{2}\alpha^2(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k - \mathbf{b}^T \mathbf{x}^k - \alpha \mathbf{b}^T \mathbf{r}^k \end{aligned}$$

- Délku kroku α_k zvolíme tak, abychom dosáhli minima f ve směru rezidua \mathbf{r}^k .
- Definujme pomocnou funkci $F: \mathbb{R} \rightarrow \mathbb{R}$

$$\begin{aligned} F(\alpha) &= f(\mathbf{x}^k + \alpha \mathbf{r}^k) = \frac{1}{2}(\mathbf{x}^k + \alpha \mathbf{r}^k)^T \mathbf{A}(\mathbf{x}^k + \alpha \mathbf{r}^k) - \mathbf{b}^T(\mathbf{x}^k + \alpha \mathbf{r}^k) = \\ &= \frac{1}{2}(\mathbf{x}^k)^T \mathbf{A} \mathbf{x}^k + \alpha(\mathbf{x}^k)^T \mathbf{A} \mathbf{r}^k + \frac{1}{2}\alpha^2(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k - \mathbf{b}^T \mathbf{x}^k - \alpha \mathbf{b}^T \mathbf{r}^k \end{aligned}$$



$$f(x_{(i)} + \alpha r_{(i)})$$



- Hledáme α , ve kterém funkce F dosahuje minima \Rightarrow její derivace tedy musí být nulová.

- Hledáme α , ve kterém funkce F dosahuje minima \Rightarrow její derivace tedy musí být nulová.

$$F'(\alpha) = \alpha(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k + (\mathbf{r}^k)^T \underbrace{\mathbf{A} \mathbf{x}^k}_{= (\mathbf{b} - \mathbf{r}^k)} - \mathbf{b}^T \mathbf{r}^k = \alpha(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k - (\mathbf{r}^k)^T \mathbf{r} = 0$$

- Hledáme α , ve kterém funkce F dosahuje minima \Rightarrow její derivace tedy musí být nulová.

$$F'(\alpha) = \alpha(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k + (\mathbf{r}^k)^T \underbrace{\mathbf{A} \mathbf{x}^k}_{= (\mathbf{b} - \mathbf{r}^k)} - \mathbf{b}^T \mathbf{r}^k = \alpha(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k - (\mathbf{r}^k)^T \mathbf{r}^k = 0$$

\Downarrow

$$\alpha_k = \frac{(\mathbf{r}^k)^T \mathbf{r}^k}{(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k}$$

- Stejný předpis získáme, pokud položíme derivaci funkce f ve směru \boldsymbol{r}^k rovnu nule.

- Stejný předpis získáme, pokud položíme derivaci funkce f ve směru \mathbf{r}^k rovnu nule.
- Nejdříve si uvědomme, že $\mathbf{r}^{k+1} = \mathbf{b} - A\mathbf{x}^{k+1} = \mathbf{b} - A(\mathbf{x}^k + \alpha_k \mathbf{r}^k) = \mathbf{r}^k - \alpha_k A\mathbf{r}^k$.

- Stejný předpis získáme, pokud položíme derivaci funkce f ve směru \mathbf{r}^k rovnu nule.
- Nejdříve si uvědomme, že $\mathbf{r}^{k+1} = \mathbf{b} - A\mathbf{x}^{k+1} = \mathbf{b} - A(\mathbf{x}^k + \alpha_k \mathbf{r}^k) = \mathbf{r}^k - \alpha_k A\mathbf{r}^k$.

$$\frac{df(\mathbf{x}^{k+1})}{d\mathbf{r}^k} = 0$$

- Stejný předpis získáme, pokud položíme derivaci funkce f ve směru \mathbf{r}^k rovnu nule.
- Nejdříve si uvědomme, že $\mathbf{r}^{k+1} = \mathbf{b} - \mathbf{A}\mathbf{x}^{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}^k + \alpha_k \mathbf{r}^k) = \mathbf{r}^k - \alpha_k \mathbf{A}\mathbf{r}^k$.

$$\begin{aligned} \frac{df(\mathbf{x}^{k+1})}{d\mathbf{r}^k} &= 0 \\ (\nabla f(\mathbf{x}^{k+1}))^T \mathbf{r}^k &= 0 \end{aligned}$$

- Stejný předpis získáme, pokud položíme derivaci funkce f ve směru \mathbf{r}^k rovnu nule.
- Nejdříve si uvědomme, že $\mathbf{r}^{k+1} = \mathbf{b} - \mathbf{A}\mathbf{x}^{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}^k + \alpha_k \mathbf{r}^k) = \mathbf{r}^k - \alpha_k \mathbf{A}\mathbf{r}^k$.

$$\frac{df(\mathbf{x}^{k+1})}{d\mathbf{r}^k} = 0$$

$$(\nabla f(\mathbf{x}^{k+1}))^T \mathbf{r}^k = 0$$

$$(-\mathbf{r}^{k+1})^T \mathbf{r}^k = 0$$

- Stejný předpis získáme, pokud položíme derivaci funkce f ve směru \mathbf{r}^k rovnu nule.
- Nejdříve si uvědomme, že $\mathbf{r}^{k+1} = \mathbf{b} - \mathbf{A}\mathbf{x}^{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}^k + \alpha_k \mathbf{r}^k) = \mathbf{r}^k - \alpha_k \mathbf{A}\mathbf{r}^k$.

$$\frac{df(\mathbf{x}^{k+1})}{d\mathbf{r}^k} = 0$$

$$(\nabla f(\mathbf{x}^{k+1}))^T \mathbf{r}^k = 0$$

$$(-\mathbf{r}^{k+1})^T \mathbf{r}^k = 0$$

$$(-\mathbf{r}^k + \alpha_k \mathbf{A}\mathbf{r}^k)^T \mathbf{r}^k = 0$$

- Stejný předpis získáme, pokud položíme derivaci funkce f ve směru \mathbf{r}^k rovnu nule.
- Nejdříve si uvědomme, že $\mathbf{r}^{k+1} = \mathbf{b} - \mathbf{A}\mathbf{x}^{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}^k + \alpha_k \mathbf{r}^k) = \mathbf{r}^k - \alpha_k \mathbf{A}\mathbf{r}^k$.

$$\frac{df(\mathbf{x}^{k+1})}{d\mathbf{r}^k} = 0$$

$$(\nabla f(\mathbf{x}^{k+1}))^T \mathbf{r}^k = 0$$

$$(-\mathbf{r}^{k+1})^T \mathbf{r}^k = 0$$

$$(-\mathbf{r}^k + \alpha_k \mathbf{A}\mathbf{r}^k)^T \mathbf{r}^k = 0$$

$$\alpha_k = \frac{(\mathbf{r}^k)^T \mathbf{r}^k}{(\mathbf{r}^k)^T \mathbf{A}\mathbf{r}^k}$$

- Algoritmus tedy počítá jednotlivé aproximace pomocí následujících předpisů:

$$\begin{aligned}\mathbf{r}^k &= \mathbf{b} - \mathbf{A}\mathbf{x}^k = \mathbf{b} - \mathbf{A}(\mathbf{x}^{k-1} + \alpha^{k-1}\mathbf{r}^{k-1}) = \underbrace{\mathbf{b} - \mathbf{A}\mathbf{x}^{k-1}}_{\mathbf{r}^{k-1}} - \alpha^{k-1}\mathbf{A}\mathbf{r}^{k-1} = \\ &= \mathbf{r}^{k-1} - \alpha^{k-1}\mathbf{A}\mathbf{r}^{k-1} \\ \alpha^k &= \frac{(\mathbf{r}^k)^T \mathbf{r}^k}{(\mathbf{r}^k)^T \mathbf{A}\mathbf{r}^k} \\ \mathbf{x}^{k+1} &= \mathbf{x}^k + \alpha^k \mathbf{r}^k\end{aligned}$$

```
function steepestd_descent( $A, b, x^0$ )  
   $r^0 = b - Ax^0$   
   $k = 0$   
  while  $\|r^k\|/\|r^0\| > \varepsilon$  do  
     $\alpha_k = ((r^k)^T r^k)/((r^k)^T A r^k)$   
     $x^{k+1} = x^k + \alpha_k r^k$   
     $r^{k+1} = r^k - \alpha_k A r^k$   
     $k = k + 1$   
  end while  
end function
```

- Konvergenci budeme dokazovat v tzv. energetické normě $\|\cdot\|_A$, tedy normě indukované skalárním součinem $(Ax, x) = x^T Ax : \|x\|_A = \sqrt{x^T Ax}$.

- Konvergenci budeme dokazovat v tzv. energetické normě $\|\cdot\|_A$, tedy normě indukované skalárním součinem $(Ax, x) = x^T Ax : \|x\|_A = \sqrt{x^T Ax}$.
- Platí $e^{k+1} = x^{k+1} - x = x^k + \alpha_k r^k - x = e^k + \alpha_k r^k$

- Konvergenci budeme dokazovat v tzv. energetické normě $\|\cdot\|_A$, tedy normě indukované skalárním součinem $(Ax, x) = x^T Ax : \|x\|_A = \sqrt{x^T Ax}$.
- Platí $e^{k+1} = x^{k+1} - x = x^k + \alpha_k r^k - x = e^k + \alpha_k r^k$
- Pro normu chyby $\|e^{k+1}\|_A$ platí

$$\|e^{k+1}\|_A^2 = (e^{k+1})^T A e^{k+1}$$

- Konvergenci budeme dokazovat v tzv. energetické normě $\|\cdot\|_A$, tedy normě indukované skalárním součinem $(Ax, x) = x^T Ax : \|x\|_A = \sqrt{x^T Ax}$.
- Platí $e^{k+1} = x^{k+1} - x = x^k + \alpha_k r^k - x = e^k + \alpha_k r^k$
- Pro normu chyby $\|e^{k+1}\|_A$ platí

$$\|e^{k+1}\|_A^2 = (e^{k+1})^T A e^{k+1} = (e^k + \alpha_k r^k)^T A (e^k + \alpha_k r^k) =$$

- Konvergenci budeme dokazovat v tzv. energetické normě $\|\cdot\|_A$, tedy normě indukované skalárním součinem $(Ax, x) = x^T Ax : \|x\|_A = \sqrt{x^T Ax}$.
- Platí $e^{k+1} = x^{k+1} - x = x^k + \alpha_k r^k - x = e^k + \alpha_k r^k$
- Pro normu chyby $\|e^{k+1}\|_A$ platí

$$\begin{aligned} \|e^{k+1}\|_A^2 &= (e^{k+1})^T A e^{k+1} = (e^k + \alpha_k r^k)^T A (e^k + \alpha_k r^k) = \\ &= (e^k)^T A e^k + 2\alpha_k (r^k)^T \underbrace{A e^k}_{=-r^k} + (\alpha_k)^2 (r^k)^T A r^k = \end{aligned}$$

- Konvergenci budeme dokazovat v tzv. energetické normě $\|\cdot\|_A$, tedy normě indukované skalárním součinem $(Ax, x) = x^T Ax : \|x\|_A = \sqrt{x^T Ax}$.
- Platí $e^{k+1} = x^{k+1} - x = x^k + \alpha_k r^k - x = e^k + \alpha_k r^k$
- Pro normu chyby $\|e^{k+1}\|_A$ platí

$$\begin{aligned}
 \|e^{k+1}\|_A^2 &= (e^{k+1})^T A e^{k+1} = (e^k + \alpha_k r^k)^T A (e^k + \alpha_k r^k) = \\
 &= (e^k)^T A e^k + 2\alpha_k (r^k)^T \underbrace{A e^k}_{=-r^k} + (\alpha_k)^2 (r^k)^T A r^k = \\
 &= \|e^k\|_A^2 - 2 \underbrace{\frac{(r^k)^T r^k}{(r^k)^T A r^k}}_{=\alpha_k} (r^k)^T r^k + \left(\frac{(r^k)^T r^k}{(r^k)^T A r^k}\right)^2 (r^k)^T A r^k =
 \end{aligned}$$

- Konvergenci budeme dokazovat v tzv. energetické normě $\|\cdot\|_A$, tedy normě indukované skalárním součinem $(Ax, x) = x^T Ax : \|x\|_A = \sqrt{x^T Ax}$.
- Platí $e^{k+1} = x^{k+1} - x = x^k + \alpha_k r^k - x = e^k + \alpha_k r^k$
- Pro normu chyby $\|e^{k+1}\|_A$ platí

$$\begin{aligned}
 \|e^{k+1}\|_A^2 &= (e^{k+1})^T A e^{k+1} = (e^k + \alpha_k r^k)^T A (e^k + \alpha_k r^k) = \\
 &= (e^k)^T A e^k + 2\alpha_k (r^k)^T \underbrace{A e^k}_{=-r^k} + (\alpha_k)^2 (r^k)^T A r^k = \\
 &= \|e^k\|_A^2 - 2 \underbrace{\frac{(r^k)^T r^k}{(r^k)^T A r^k}}_{=\alpha_k} (r^k)^T r^k + \left(\frac{(r^k)^T r^k}{(r^k)^T A r^k}\right)^2 (r^k)^T A r^k = \\
 &= \|e^k\|_A^2 - \frac{((r^k)^T r^k)^2}{(r^k)^T A r^k} =
 \end{aligned}$$

- Konvergenci budeme dokazovat v tzv. energetické normě $\|\cdot\|_A$, tedy normě indukované skalárním součinem $(Ax, x) = x^T Ax : \|x\|_A = \sqrt{x^T Ax}$.
- Platí $e^{k+1} = x^{k+1} - x = x^k + \alpha_k r^k - x = e^k + \alpha_k r^k$
- Pro normu chyby $\|e^{k+1}\|_A$ platí

$$\begin{aligned}
 \|e^{k+1}\|_A^2 &= (e^{k+1})^T A e^{k+1} = (e^k + \alpha_k r^k)^T A (e^k + \alpha_k r^k) = \\
 &= (e^k)^T A e^k + 2\alpha_k (r^k)^T \underbrace{A e^k}_{=-r^k} + (\alpha_k)^2 (r^k)^T A r^k = \\
 &= \|e^k\|_A^2 - 2 \underbrace{\frac{(r^k)^T r^k}{(r^k)^T A r^k}}_{=\alpha_k} (r^k)^T r^k + \left(\frac{(r^k)^T r^k}{(r^k)^T A r^k}\right)^2 (r^k)^T A r^k = \\
 &= \|e^k\|_A^2 - \frac{((r^k)^T r^k)^2}{(r^k)^T A r^k} = \\
 &= \|e^k\|_A^2 \left(1 - \frac{((r^k)^T r^k)^2}{((r^k)^T A r^k) \underbrace{((e^k)^T A e^k)}_{=(A^{-1} r^k)^T A (A^{-1} r^k) = (r^k)^T A^{-1} r^k}}\right).
 \end{aligned}$$

- Chyba v kroku $k + 1$ je tedy nějakým násobkem chyby v kroku k .

- Chyba v kroku $k + 1$ je tedy nějakým násobkem chyby v kroku k .
- Dle Cauchyho-Schwarzovy nerovnosti a definice maticové normy indukované vektorovou normou platí

$$|(\mathbf{r}^k)^T A \mathbf{r}^k| \leq \|\mathbf{r}^k\| \cdot \|A \mathbf{r}^k\| \leq \|\mathbf{r}^k\| \cdot \|A\| \cdot \|\mathbf{r}^k\| = \|\mathbf{r}^k\|^2 \|A\|$$

- Chyba v kroku $k + 1$ je tedy nějakým násobkem chyby v kroku k .
- Dle Cauchyho-Schwarzovy nerovnosti a definice maticové normy indukované vektorovou normou platí

$$|(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A} \mathbf{r}^k\| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A}\| \cdot \|\mathbf{r}^k\| = \|\mathbf{r}^k\|^2 \|\mathbf{A}\|$$

- Podívejme se na koeficient z předchozího odhadu podrobněji

$$1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{((\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k)((\mathbf{r}^k)^T \mathbf{A}^{-1} \mathbf{r}^k)}$$

- Chyba v kroku $k + 1$ je tedy nějakým násobkem chyby v kroku k .
- Dle Cauchyho-Schwarzovy nerovnosti a definice maticové normy indukované vektorovou normou platí

$$|(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A} \mathbf{r}^k\| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A}\| \cdot \|\mathbf{r}^k\| = \|\mathbf{r}^k\|^2 \|\mathbf{A}\|$$

- Podívejme se na koeficient z předchozího odhadu podrobněji

$$1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{((\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k)((\mathbf{r}^k)^T \mathbf{A}^{-1} \mathbf{r}^k)} \leq 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{\|\mathbf{A}\| \cdot \|\mathbf{r}^k\|^2 \cdot \|\mathbf{A}^{-1}\| \cdot \|\mathbf{r}^k\|^2}$$

- Chyba v kroku $k + 1$ je tedy nějakým násobkem chyby v kroku k .
- Dle Cauchyho-Schwarzovy nerovnosti a definice maticové normy indukované vektorovou normou platí

$$|(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A} \mathbf{r}^k\| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A}\| \cdot \|\mathbf{r}^k\| = \|\mathbf{r}^k\|^2 \|\mathbf{A}\|$$

- Podívejme se na koeficient z předchozího odhadu podrobněji

$$\begin{aligned} 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{((\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k)((\mathbf{r}^k)^T \mathbf{A}^{-1} \mathbf{r}^k)} &\leq 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{\|\mathbf{A}\| \cdot \|\mathbf{r}^k\|^2 \cdot \|\mathbf{A}^{-1}\| \cdot \|\mathbf{r}^k\|^2} = \\ &= 1 - \frac{1}{\|\mathbf{A}\| \|\mathbf{A}^{-1}\|} \end{aligned}$$

- Chyba v kroku $k + 1$ je tedy nějakým násobkem chyby v kroku k .
- Dle Cauchyho-Schwarzovy nerovnosti a definice maticové normy indukované vektorovou normou platí

$$|(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A} \mathbf{r}^k\| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A}\| \cdot \|\mathbf{r}^k\| = \|\mathbf{r}^k\|^2 \|\mathbf{A}\|$$

- Podívejme se na koeficient z předchozího odhadu podrobněji

$$\begin{aligned} 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{((\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k)((\mathbf{r}^k)^T \mathbf{A}^{-1} \mathbf{r}^k)} &\leq 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{\|\mathbf{A}\| \cdot \|\mathbf{r}^k\|^2 \cdot \|\mathbf{A}^{-1}\| \cdot \|\mathbf{r}^k\|^2} = \\ &= 1 - \frac{1}{\|\mathbf{A}\| \|\mathbf{A}^{-1}\|} = q. \end{aligned}$$

- Chyba v kroku $k + 1$ je tedy nějakým násobkem chyby v kroku k .
- Dle Cauchyho-Schwarzovy nerovnosti a definice maticové normy indukované vektorovou normou platí

$$|(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A} \mathbf{r}^k\| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A}\| \cdot \|\mathbf{r}^k\| = \|\mathbf{r}^k\|^2 \|\mathbf{A}\|$$

- Podívejme se na koeficient z předchozího odhadu podrobněji

$$\begin{aligned} 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{((\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k)((\mathbf{r}^k)^T \mathbf{A}^{-1} \mathbf{r}^k)} &\leq 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{\|\mathbf{A}\| \cdot \|\mathbf{r}^k\|^2 \cdot \|\mathbf{A}^{-1}\| \cdot \|\mathbf{r}^k\|^2} = \\ &= 1 - \frac{1}{\|\mathbf{A}\| \|\mathbf{A}^{-1}\|} = q. \end{aligned}$$

- Výraz $\|\mathbf{A}\| \|\mathbf{A}^{-1}\|$ nazýváme číslem podmíněnosti a v případě symetrické pozitivně definitní matice jej vypočítáme jako podíl největšího a nejmenšího vlastního čísla $\kappa(\mathbf{A}) = \frac{\lambda_{\max}}{\lambda_{\min}}$.

- Chyba v kroku $k + 1$ je tedy nějakým násobkem chyby v kroku k .
- Dle Cauchyho-Schwarzovy nerovnosti a definice maticové normy indukované vektorovou normou platí

$$|(\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A} \mathbf{r}^k\| \leq \|\mathbf{r}^k\| \cdot \|\mathbf{A}\| \cdot \|\mathbf{r}^k\| = \|\mathbf{r}^k\|^2 \|\mathbf{A}\|$$

- Podívejme se na koeficient z předchozího odhadu podrobněji

$$\begin{aligned} 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{((\mathbf{r}^k)^T \mathbf{A} \mathbf{r}^k)((\mathbf{r}^k)^T \mathbf{A}^{-1} \mathbf{r}^k)} &\leq 1 - \frac{((\mathbf{r}^k)^T \mathbf{r}^k)^2}{\|\mathbf{A}\| \cdot \|\mathbf{r}^k\|^2 \cdot \|\mathbf{A}^{-1}\| \cdot \|\mathbf{r}^k\|^2} = \\ &= 1 - \frac{1}{\|\mathbf{A}\| \|\mathbf{A}^{-1}\|} = q. \end{aligned}$$

- Výraz $\|\mathbf{A}\| \|\mathbf{A}^{-1}\|$ nazýváme číslem podmíněnosti a v případě symetrické pozitivně definitní matice jej vypočítáme jako podíl největšího a nejmenšího vlastního čísla $\kappa(\mathbf{A}) = \frac{\lambda_{\max}}{\lambda_{\min}}$.
- Protože $\kappa(\mathbf{A}) = \lambda_{\max} / \lambda_{\min} \geq 1$, platí $q = 1 - 1/\kappa(\mathbf{A}) < 1$. Chyba se tedy v každém kroku zmenšuje a metoda konverguje k řešení.


- O chybě metody největšího spádu tedy platí

$$\|e^{k+1}\|_A^2 \leq \left(1 - \frac{1}{\kappa(A)}\right) \|e^k\|_A^2.$$

- Dále lze ukázat

$$\|e^{k+1}\|_A \leq \left(\frac{\kappa(A) - 1}{\kappa(A) + 1}\right)^k \|e^0\|_A.$$

- Ze vztahu $(\mathbf{r}^k)^T \mathbf{r}^{k+1} = 0$ vyplývá, že směr, ve kterém se vydáme, je kolmý k předchozímu směru.
- Při nevhodně zvoleném počátečním vektoru se může stát, že se několikrát vydáme ve stejném směru a postupně zkracujeme délku kroku.
- Procházíme tedy “cik-cak” údolí tvořené grafem minimalizované kvadratické formy.
- Toto může vést k velkému počtu iterací potřebných k řešení soustavy.





- Ideální by bylo najít metodu, která by minimalizovala celkovou chybu v daném směru vždy pouze jednou (v každé iteraci vynulovala chybu v daném směru).

- Ideální by bylo najít metodu, která by minimalizovala celkovou chybu v daném směru vždy pouze jednou (v každé iteraci vynulovala chybu v daném směru).
- Taková metoda by byla schopná vyřešit soustavu o n neznámých během n iterací.

- Ideální by bylo najít metodu, která by minimalizovala celkovou chybu v daném směru vždy pouze jednou (v každé iteraci vynulovala chybu v daném směru).
- Taková metoda by byla schopná vyřešit soustavu o n neznámých během n iterací.
- Zkusme si tedy pro $A \in \mathbb{R}^{n \times n}$ zvolit n navzájem ortogonálních směrů $\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}$ (např. rovnoběžných s osami souřadnic) a použít předpis: $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Je třeba vhodně zvolit α_k .

- Ideální by bylo najít metodu, která by minimalizovala celkovou chybu v daném směru vždy pouze jednou (v každé iteraci vynulovala chybu v daném směru).
- Taková metoda by byla schopná vyřešit soustavu o n neznámých během n iterací.
- Zkusme si tedy pro $A \in \mathbb{R}^{n \times n}$ zvolit n navzájem ortogonálních směrů d^0, d^1, \dots, d^{n-1} (např. rovnoběžných s osami souřadnic) a použít předpis: $x^{k+1} = x^k + \alpha_k d^k$.
- Je třeba vhodně zvolit α_k .



- Z obrázku je patrné, že abychom vynulovali chybu ve směru osy x , musíme bod x^1 zvolit tak, aby vektor nové chyby e^1 byl kolmý k d^0 .

$$(d^k)^T e^{k+1} = 0.$$

- Z definice chyby dostaneme

$$0 = (d^k)^T (x^{k+1} - x)$$

- Z obrázku je patrné, že abychom vynulovali chybu ve směru osy x , musíme bod x^1 zvolit tak, aby vektor nové chyby e^1 byl kolmý k d^0 .

$$(d^k)^T e^{k+1} = 0.$$

- Z definice chyby dostaneme

$$0 = (d^k)^T (x^{k+1} - x) = (d^k)^T (x^k + \alpha_k d^k - x)$$

- Z obrázku je patrné, že abychom vynulovali chybu ve směru osy x , musíme bod \boldsymbol{x}^1 zvolit tak, aby vektor nové chyby \boldsymbol{e}^1 byl kolmý k \boldsymbol{d}^0 .

$$(\boldsymbol{d}^k)^T \boldsymbol{e}^{k+1} = 0.$$

- Z definice chyby dostaneme

$$0 = (\boldsymbol{d}^k)^T (\boldsymbol{x}^{k+1} - \boldsymbol{x}) = (\boldsymbol{d}^k)^T (\boldsymbol{x}^k + \alpha_k \boldsymbol{d}^k - \boldsymbol{x}) = (\boldsymbol{d}^k)^T (\boldsymbol{e}^k + \alpha_k \boldsymbol{d}^k)$$

- Z obrázku je patrné, že abychom vynulovali chybu ve směru osy x , musíme bod \mathbf{x}^1 zvolit tak, aby vektor nové chyby \mathbf{e}^1 byl kolmý k \mathbf{d}^0 .

$$(\mathbf{d}^k)^T \mathbf{e}^{k+1} = 0.$$

- Z definice chyby dostaneme

$$0 = (\mathbf{d}^k)^T (\mathbf{x}^{k+1} - \mathbf{x}) = (\mathbf{d}^k)^T (\mathbf{x}^k + \alpha_k \mathbf{d}^k - \mathbf{x}) = (\mathbf{d}^k)^T (\mathbf{e}^k + \alpha_k \mathbf{d}^k)$$

$$\Downarrow$$

$$\alpha_k = -\frac{(\mathbf{d}^k)^T \mathbf{e}^k}{(\mathbf{d}^k)^T \mathbf{d}^k}.$$

- Z obrázku je patrné, že abychom vynulovali chybu ve směru osy x , musíme bod \mathbf{x}^1 zvolit tak, aby vektor nové chyby \mathbf{e}^1 byl kolmý k \mathbf{d}^0 .

$$(\mathbf{d}^k)^T \mathbf{e}^{k+1} = 0.$$

- Z definice chyby dostaneme

$$0 = (\mathbf{d}^k)^T (\mathbf{x}^{k+1} - \mathbf{x}) = (\mathbf{d}^k)^T (\mathbf{x}^k + \alpha_k \mathbf{d}^k - \mathbf{x}) = (\mathbf{d}^k)^T (\mathbf{e}^k + \alpha_k \mathbf{d}^k)$$

$$\Downarrow$$

$$\alpha_k = -\frac{(\mathbf{d}^k)^T \mathbf{e}^k}{(\mathbf{d}^k)^T \mathbf{d}^k}.$$

- Pro výpočet α_k bychom potřebovali znát chybu \mathbf{e}^k – takto tedy postupovat nemůžeme.

- Z obrázku je patrné, že abychom vynulovali chybu ve směru osy x , musíme bod \mathbf{x}^1 zvolit tak, aby vektor nové chyby \mathbf{e}^1 byl kolmý k \mathbf{d}^0 .

$$(\mathbf{d}^k)^T \mathbf{e}^{k+1} = 0.$$

- Z definice chyby dostaneme

$$0 = (\mathbf{d}^k)^T (\mathbf{x}^{k+1} - \mathbf{x}) = (\mathbf{d}^k)^T (\mathbf{x}^k + \alpha_k \mathbf{d}^k - \mathbf{x}) = (\mathbf{d}^k)^T (\mathbf{e}^k + \alpha_k \mathbf{d}^k)$$

$$\Downarrow$$

$$\alpha_k = - \frac{(\mathbf{d}^k)^T \mathbf{e}^k}{(\mathbf{d}^k)^T \mathbf{d}^k}.$$

- Pro výpočet α_k bychom potřebovali znát chybu \mathbf{e}^k – takto tedy postupovat nemůžeme.
- Ukážeme si ale, že pokud požadavek na ortogonalitu nahradíme za požadavek na tzv. A-ortogonalitu, budeme schopní příslušné koeficienty α_k najít.

Metoda sdružených gradientů

Definice

Bud' A symetrická pozitivně definitní matice. Nenulové vektory $\{\mathbf{p}_i\}_{i=0}^{n-1}$ nazveme sdružené (A -ortogonální), platí-li

$$\forall i, j \in \{0, 1, \dots, n-1\} : i \neq j \Rightarrow \mathbf{p}_i^T A \mathbf{p}_j = 0.$$

Dva navzájem A -ortogonální vektory někdy označujeme $\mathbf{a} \perp_A \mathbf{b}$.

Lemma

Prvky množiny sdružených vektorů jsou lineárně nezávislé.

Lemma

Prvky množiny sdružených vektorů jsou lineárně nezávislé.

Dk.

- Chceme ukázat

$$\alpha_0 \mathbf{p}_0 + \alpha_1 \mathbf{p}_1 + \dots + \alpha_{n-1} \mathbf{p}_{n-1} = 0 \Rightarrow \forall i : \alpha_i = 0$$

Lemma

Prvky množiny sdružených vektorů jsou lineárně nezávislé.

Dk.

- Chceme ukázat

$$\alpha_0 \mathbf{p}_0 + \alpha_1 \mathbf{p}_1 + \dots + \alpha_{n-1} \mathbf{p}_{n-1} = 0 \Rightarrow \forall i : \alpha_i = 0$$

- Přenásobme rovnici výrazem $(A\mathbf{p}_k)^T, k \in \{0, 1, \dots, n-1\}$ zleva:

$$\alpha_0 \mathbf{p}_k^T A \mathbf{p}_0 + \alpha_1 \mathbf{p}_k^T A \mathbf{p}_1 + \dots + \alpha_{n-1} \mathbf{p}_k^T A \mathbf{p}_{n-1} = 0$$

Lemma

Prvky množiny sdružených vektorů jsou lineárně nezávislé.

Dk.

- Chceme ukázat

$$\alpha_0 \mathbf{p}_0 + \alpha_1 \mathbf{p}_1 + \dots + \alpha_{n-1} \mathbf{p}_{n-1} = 0 \Rightarrow \forall i : \alpha_i = 0$$

- Přenásobme rovnici výrazem $(\mathbf{A}\mathbf{p}_k)^T, k \in \{0, 1, \dots, n-1\}$ zleva:

$$\alpha_0 \mathbf{p}_k^T \mathbf{A} \mathbf{p}_0 + \alpha_1 \mathbf{p}_k^T \mathbf{A} \mathbf{p}_1 + \dots + \alpha_{n-1} \mathbf{p}_k^T \mathbf{A} \mathbf{p}_{n-1} = 0$$

- vektory sdružené \Rightarrow všechny členy v této sumě až na jeden jsou nulové:

$$\alpha_k \mathbf{p}_k^T \mathbf{A} \mathbf{p}_k = 0.$$

Lemma

Prvky množiny sdružených vektorů jsou lineárně nezávislé.

Dk.

- Chceme ukázat

$$\alpha_0 \mathbf{p}_0 + \alpha_1 \mathbf{p}_1 + \dots + \alpha_{n-1} \mathbf{p}_{n-1} = 0 \Rightarrow \forall i : \alpha_i = 0$$

- Přenásobme rovnici výrazem $(\mathbf{A} \mathbf{p}_k)^T, k \in \{0, 1, \dots, n-1\}$ zleva:

$$\alpha_0 \mathbf{p}_k^T \mathbf{A} \mathbf{p}_0 + \alpha_1 \mathbf{p}_k^T \mathbf{A} \mathbf{p}_1 + \dots + \alpha_{n-1} \mathbf{p}_k^T \mathbf{A} \mathbf{p}_{n-1} = 0$$

- vektory sdružené \Rightarrow všechny členy v této sumě až na jeden jsou nulové:

$$\alpha_k \mathbf{p}_k^T \mathbf{A} \mathbf{p}_k = 0.$$

- A je symetrická pozitivně definitní, takže $\mathbf{p}_k^T \mathbf{A} \mathbf{p}_k > 0$. Tedy $\alpha_k = 0$. \square

- Místo n ortogonálních směrů volme n A -ortogonálních směrů $\{d^0, d^1, \dots, d^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $x^{k+1} = x^k + \alpha_k d^k$.

- Místo n ortogonálních směrů volme n A-ortogonálních směrů $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Požadavek na ortogonalitu chyby a směru nahradíme za jejich A-ortogonalitu, tzn. $\mathbf{e}^{k+1} \perp_A \mathbf{d}^k$.

- Místo n ortogonálních směrů volme n A-ortogonálních směrů $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Požadavek na ortogonalitu chyby a směru nahradíme za jejich A-ortogonalitu, tzn. $\mathbf{e}^{k+1} \perp_A \mathbf{d}^k$. Toto nastane v minimu $f(\mathbf{x}) = 1/2 \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$ ve směru \mathbf{d}^k :

- Místo n ortogonálních směrů volme n A-ortogonálních směrů $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Požadavek na ortogonalitu chyby a směru nahradíme za jejich A-ortogonalitu, tzn. $\mathbf{e}^{k+1} \perp_A \mathbf{d}^k$. Toto nastane v minimu $f(\mathbf{x}) = 1/2 \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$ ve směru \mathbf{d}^k :

$$0 = \frac{\mathrm{d}f(\mathbf{x}^{k+1})}{\mathrm{d}\mathbf{d}^k}$$

- Místo n ortogonálních směrů volme n A-ortogonálních směrů $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Požadavek na ortogonalitu chyby a směru nahradíme za jejich A-ortogonalitu, tzn. $\mathbf{e}^{k+1} \perp_A \mathbf{d}^k$. Toto nastane v minimu $f(\mathbf{x}) = 1/2 \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$ ve směru \mathbf{d}^k :

$$0 = \frac{\mathrm{d}f(\mathbf{x}^{k+1})}{\mathrm{d}\mathbf{d}^k} = \mathrm{grad} f(\mathbf{x}^{k+1})^T \mathbf{d}^k$$

- Místo n ortogonálních směrů volme n A-ortogonálních směrů $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Požadavek na ortogonalitu chyby a směru nahradíme za jejich A-ortogonalitu, tzn. $\mathbf{e}^{k+1} \perp_A \mathbf{d}^k$. Toto nastane v minimu $f(\mathbf{x}) = 1/2 \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$ ve směru \mathbf{d}^k :

$$0 = \frac{df(\mathbf{x}^{k+1})}{d\mathbf{d}^k} = \text{grad} f(\mathbf{x}^{k+1})^T \mathbf{d}^k = -(\underbrace{\mathbf{r}^{k+1}}_{= -\mathbf{A} \mathbf{e}^{k+1}})^T \mathbf{d}^k$$

- Místo n ortogonálních směrů volme n A-ortogonálních směrů $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Požadavek na ortogonalitu chyby a směru nahradíme za jejich A-ortogonalitu, tzn. $\mathbf{e}^{k+1} \perp_A \mathbf{d}^k$. Toto nastane v minimu $f(\mathbf{x}) = 1/2 \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$ ve směru \mathbf{d}^k :

$$0 = \frac{df(\mathbf{x}^{k+1})}{d\mathbf{d}^k} = \text{grad} f(\mathbf{x}^{k+1})^T \mathbf{d}^k = -(\underbrace{\mathbf{r}^{k+1}}_{= -\mathbf{A}\mathbf{e}^{k+1}})^T \mathbf{d}^k = (\mathbf{e}^{k+1})^T \mathbf{A} \mathbf{d}^k.$$

- Místo n ortogonálních směrů volme n A-ortogonálních směrů $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Požadavek na ortogonalitu chyby a směru nahradíme za jejich A-ortogonalitu, tzn. $\mathbf{e}^{k+1} \perp_A \mathbf{d}^k$. Toto nastane v minimu $f(\mathbf{x}) = 1/2 \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$ ve směru \mathbf{d}^k :

$$0 = \frac{df(\mathbf{x}^{k+1})}{d\mathbf{d}^k} = \text{grad} f(\mathbf{x}^{k+1})^T \mathbf{d}^k = -(\underbrace{\mathbf{r}^{k+1}}_{= -\mathbf{A}\mathbf{e}^{k+1}})^T \mathbf{d}^k = (\mathbf{e}^{k+1})^T \mathbf{A} \mathbf{d}^k.$$

- Nyní snadno nalezneme koeficient α_k

$$(\mathbf{e}^{k+1})^T \mathbf{A} \mathbf{d}^k = (\mathbf{e}^k + \alpha_k \mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k = 0$$

- Místo n ortogonálních směrů volme n A-ortogonálních směrů $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^{n-1}\}$ a pokusme se odvodit iterační metodu ve tvaru $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$.
- Požadavek na ortogonalitu chyby a směru nahradíme za jejich A-ortogonalitu, tzn. $\mathbf{e}^{k+1} \perp_A \mathbf{d}^k$. Toto nastane v minimu $f(\mathbf{x}) = 1/2 \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$ ve směru \mathbf{d}^k :

$$0 = \frac{df(\mathbf{x}^{k+1})}{d\mathbf{d}^k} = \text{grad} f(\mathbf{x}^{k+1})^T \mathbf{d}^k = -(\underbrace{\mathbf{r}^{k+1}}_{= -\mathbf{A} \mathbf{e}^{k+1}})^T \mathbf{d}^k = (\mathbf{e}^{k+1})^T \mathbf{A} \mathbf{d}^k.$$

- Nyní snadno nalezneme koeficient α_k

$$(\mathbf{e}^{k+1})^T \mathbf{A} \mathbf{d}^k = (\mathbf{e}^k + \alpha_k \mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k = 0 \Rightarrow \alpha_k = -\frac{(\mathbf{e}^k)^T \mathbf{A} \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k} = \frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k}$$

Věta

Algoritmus nalezne přesné řešení x v nejvýše n krocích.

Věta

Algoritmus nalezne přesné řešení x v nejvýše n krocích.

Dk.

- Vyjádříme e^0 v bázi tvořené A -ortogonálními (tedy nezávislými) vektory $\{d^i\}_{i=0}^{n-1}$:

$$e^0 = \sum_{j=0}^{n-1} \delta_j d^j.$$

Věta

Algoritmus nalezne přesné řešení x v nejvýše n krocích.

Dk.

- Vyjádříme e^0 v bázi tvořené A -ortogonálními (tedy nezávislými) vektory $\{d^i\}_{i=0}^{n-1}$:

$$e^0 = \sum_{j=0}^{n-1} \delta_j d^j.$$

- Přenásobme $(d^k)^T A, k \in \{0, 1, \dots, n-1\}$ zleva

$$(d^k)^T A e^0 = \sum_{j=0}^{n-1} \delta_j (d^k)^T A d^j = \delta_k (d^k)^T A d^k.$$

Věta

Algoritmus nalezne přesné řešení x v nejvýše n krocích.

Dk.

- Vyjádříme e^0 v bázi tvořené A -ortogonálními (tedy nezávislými) vektory $\{d^i\}_{i=0}^{n-1}$:

$$e^0 = \sum_{j=0}^{n-1} \delta_j d^j.$$

- Přenásobme $(d^k)^T A, k \in \{0, 1, \dots, n-1\}$ zleva

$$(d^k)^T A e^0 = \sum_{j=0}^{n-1} \delta_j (d^k)^T A d^j = \delta_k (d^k)^T A d^k.$$

- Odtud

$$\delta_k = \frac{(d^k)^T A e^0}{(d^k)^T A d^k}$$

Věta

Algoritmus nalezne přesné řešení x v nejvýše n krocích.

Dk.

- Vyjádříme e^0 v bázi tvořené A-ortogonálními (tedy nezávislými) vektory $\{d^i\}_{i=0}^{n-1}$:

$$e^0 = \sum_{j=0}^{n-1} \delta_j d^j.$$

- Přenásobme $(d^k)^T A, k \in \{0, 1, \dots, n-1\}$ zleva

$$(d^k)^T A e^0 = \sum_{j=0}^{n-1} \delta_j (d^k)^T A d^j = \delta_k (d^k)^T A d^k.$$

- Odtud

$$\delta_k = \frac{(d^k)^T A e^0}{(d^k)^T A d^k} = \frac{(d^k)^T A (e^0 + \sum_{i=0}^{k-1} \alpha_i d^i)}{(d^k)^T A d^k}$$

Věta

Algoritmus nalezne přesné řešení x v nejvýše n krocích.

Dk.

- Vyjádříme e^0 v bázi tvořené A-ortogonálními (tedy nezávislými) vektory $\{d^i\}_{i=0}^{n-1}$:

$$e^0 = \sum_{j=0}^{n-1} \delta_j d^j.$$

- Přenásobme $(d^k)^T A, k \in \{0, 1, \dots, n-1\}$ zleva

$$(d^k)^T A e^0 = \sum_{j=0}^{n-1} \delta_j (d^k)^T A d^j = \delta_k (d^k)^T A d^k.$$

- Odtud

$$\delta_k = \frac{(d^k)^T A e^0}{(d^k)^T A d^k} = \frac{(d^k)^T A (e^0 + \sum_{i=0}^{k-1} \alpha_i d^i)}{(d^k)^T A d^k} = \frac{(d^k)^T A e^k}{(d^k)^T A d^k}$$

Věta

Algoritmus nalezne přesné řešení x v nejvýše n krocích.

Dk.

- Vyjádříme e^0 v bázi tvořené A-ortogonálními (tedy nezávislými) vektory $\{d^i\}_{i=0}^{n-1}$:

$$e^0 = \sum_{j=0}^{n-1} \delta_j d^j.$$

- Přenásobme $(d^k)^T A, k \in \{0, 1, \dots, n-1\}$ zleva

$$(d^k)^T A e^0 = \sum_{j=0}^{n-1} \delta_j (d^k)^T A d^j = \delta_k (d^k)^T A d^k.$$

- Odtud

$$\delta_k = \frac{(d^k)^T A e^0}{(d^k)^T A d^k} = \frac{(d^k)^T A (e^0 + \sum_{i=0}^{k-1} \alpha_i d^i)}{(d^k)^T A d^k} = \frac{(d^k)^T A e^k}{(d^k)^T A d^k} = -\frac{(d^k)^T r^k}{(d^k)^T A d^k}.$$

■ Porovnejme

$$\alpha_k = \frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k} \quad \text{vs.} \quad \delta_k = -\frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k}$$

■ Porovnejme

$$\alpha_k = \frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k} \quad \text{vs.} \quad \delta_k = -\frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k}$$

■ Vyjádřeme si tedy chybu v i -té iteraci jako

$$\mathbf{e}^i = \mathbf{e}^0 + \sum_{j=0}^{i-1} \alpha_j \mathbf{d}^j$$

■ Porovnejme

$$\alpha_k = \frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k} \quad \text{vs.} \quad \delta_k = -\frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k}$$

■ Vyjádřeme si tedy chybu v i -té iteraci jako

$$\mathbf{e}^i = \mathbf{e}^0 + \sum_{j=0}^{i-1} \alpha_j \mathbf{d}^j = \sum_{j=0}^{n-1} \delta_j \mathbf{d}^j + \sum_{j=0}^{i-1} \alpha_j \mathbf{d}^j$$

■ Porovnejme

$$\alpha_k = \frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k} \quad \text{vs.} \quad \delta_k = -\frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k}$$

■ Vyjádřeme si tedy chybu v i -té iteraci jako

$$\mathbf{e}^i = \mathbf{e}^0 + \sum_{j=0}^{i-1} \alpha_j \mathbf{d}^j = \sum_{j=0}^{n-1} \delta_j \mathbf{d}^j + \sum_{j=0}^{i-1} \alpha_j \mathbf{d}^j = \sum_{j=0}^{n-1} \delta_j \mathbf{d}^j - \sum_{j=0}^{i-1} \delta_j \mathbf{d}^j$$

■ Porovnejme

$$\alpha_k = \frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k} \quad \text{vs.} \quad \delta_k = -\frac{(\mathbf{r}^k)^T \mathbf{d}^k}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k}$$

■ Vyjádřeme si tedy chybu v i -té iteraci jako

$$\mathbf{e}^i = \mathbf{e}^0 + \sum_{j=0}^{i-1} \alpha_j \mathbf{d}^j = \sum_{j=0}^{n-1} \delta_j \mathbf{d}^j + \sum_{j=0}^{i-1} \alpha_j \mathbf{d}^j = \sum_{j=0}^{n-1} \delta_j \mathbf{d}^j - \sum_{j=0}^{i-1} \delta_j \mathbf{d}^j = \sum_{j=i}^{n-1} \delta_j \mathbf{d}^j.$$

- V každé iteraci se odstraní jedna složka počáteční chyby \mathbf{e}^0 . Po n iteracích je každá složka chyby v bázi $\{\mathbf{d}^i\}_{i=0}^{n-1}$ vynulovaná $\Rightarrow \mathbf{e}^n = \mathbf{o}$.



- Zbývá nalézt jednotlivé A -ortogonální směry.

- Zbývá nalézt jednotlivé A -ortogonální směry.
- Předpokládejme, že známe $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$ a hledejme \mathbf{d}^{k+1} .

- Zbývá nalézt jednotlivé A-ortogonální směry.
- Předpokládejme, že známe $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$ a hledíme \mathbf{d}^{k+1} .
- Vyjdeme z vektoru \mathbf{r}^{k+1} a pomocí Gramova-Schmidtova procesu jej A-ortogonalizujeme vůči všem předchozím vektorům $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$

$$\mathbf{d}^{k+1} = \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} \mathbf{d}^j$$

- Zbývá nalézt jednotlivé A-ortogonální směry.
- Předpokládejme, že známe $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$ a hledíme \mathbf{d}^{k+1} .
- Vyjdeme z vektoru \mathbf{r}^{k+1} a pomocí Gramova-Schmidtova procesu jej A-ortogonalizujeme vůči všem předchozím vektorům $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$

$$\mathbf{d}^{k+1} = \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} \mathbf{d}^j$$

$$(\mathbf{d}^i)^T \mathbf{A} \mathbf{d}^{k+1} = (\mathbf{d}^i)^T \mathbf{A} \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} (\mathbf{d}^i)^T \mathbf{A} \mathbf{d}^j, \quad i \in \{0, 1, \dots, k\}$$

- Zbývá nalézt jednotlivé A-ortogonální směry.
- Předpokládejme, že známe $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$ a hledíme \mathbf{d}^{k+1} .
- Vyjdeme z vektoru \mathbf{r}^{k+1} a pomocí Gramova-Schmidtova procesu jej A-ortogonalizujeme vůči všem předchozím vektorům $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$

$$\mathbf{d}^{k+1} = \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} \mathbf{d}^j$$

$$(\mathbf{d}^i)^T A \mathbf{d}^{k+1} = (\mathbf{d}^i)^T A \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} (\mathbf{d}^i)^T A \mathbf{d}^j, \quad i \in \{0, 1, \dots, k\}$$

$$0 = (\mathbf{d}^i)^T A \mathbf{r}^{k+1} - \beta_{k,i} (\mathbf{d}^i)^T A \mathbf{d}^i$$

- Zbývá nalézt jednotlivé A-ortogonální směry.
- Předpokládejme, že známe $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$ a hledíme \mathbf{d}^{k+1} .
- Vyjdeme z vektoru \mathbf{r}^{k+1} a pomocí Gramova-Schmidtova procesu jej A-ortogonalizujeme vůči všem předchozím vektorům $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$

$$\mathbf{d}^{k+1} = \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} \mathbf{d}^j$$

$$(\mathbf{d}^i)^T A \mathbf{d}^{k+1} = (\mathbf{d}^i)^T A \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} (\mathbf{d}^i)^T A \mathbf{d}^j, \quad i \in \{0, 1, \dots, k\}$$

$$0 = (\mathbf{d}^i)^T A \mathbf{r}^{k+1} - \beta_{k,i} (\mathbf{d}^i)^T A \mathbf{d}^i \Rightarrow \beta_{k,i} = \frac{(\mathbf{d}^i)^T A \mathbf{r}^{k+1}}{(\mathbf{d}^i)^T A \mathbf{d}^i}$$

- Zbývá nalézt jednotlivé A-ortogonální směry.
- Předpokládejme, že známe $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$ a hledejme \mathbf{d}^{k+1} .
- Vyjdeme z vektoru \mathbf{r}^{k+1} a pomocí Gramova-Schmidtova procesu jej A-ortogonalizujeme vůči všem předchozím vektorům $\{\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k\}$

$$\mathbf{d}^{k+1} = \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} \mathbf{d}^j$$

$$(\mathbf{d}^i)^T A \mathbf{d}^{k+1} = (\mathbf{d}^i)^T A \mathbf{r}^{k+1} - \sum_{j=0}^k \beta_{k,j} (\mathbf{d}^i)^T A \mathbf{d}^j, \quad i \in \{0, 1, \dots, k\}$$

$$0 = (\mathbf{d}^i)^T A \mathbf{r}^{k+1} - \beta_{k,i} (\mathbf{d}^i)^T A \mathbf{d}^i \Rightarrow \beta_{k,i} = \frac{(\mathbf{d}^i)^T A \mathbf{r}^{k+1}}{(\mathbf{d}^i)^T A \mathbf{d}^i}$$

$$\Rightarrow \mathbf{d}^{k+1} = \mathbf{r}^{k+1} - \sum_{j=0}^k \frac{(\mathbf{d}^j)^T A \mathbf{r}^{k+1}}{(\mathbf{d}^j)^T A \mathbf{d}^j} \mathbf{d}^j.$$

- Abychom pomocí tohoto vzorce vypočítali nový směr, museli bychom si pamatovat všechny předchozí směry. Ukážeme si nyní, že všechny koeficienty $\beta_{k,j}$ kromě $\beta_{k,k}$ jsou nulové.

Lemma

Reziduum \mathbf{r}^{k+1} je ortogonální k $\mathbf{d}^0, \mathbf{d}^1, \dots, \mathbf{d}^k$.

Dk.

- Přenásobme \mathbf{r}^{k+1} vektory $\mathbf{d}^i, i \in \{0, 1, \dots, k\}$.

$$(\mathbf{d}^i)^T \underbrace{\mathbf{r}^{k+1}}_{=-\mathbf{A}\mathbf{e}^{k+1}} = -(\mathbf{d}^i)^T \mathbf{A}\mathbf{e}^{k+1} = -(\mathbf{d}^i)^T \mathbf{A} \sum_{j=k+1}^{n-1} \delta_j \mathbf{d}^j = 0,$$



Lemma

Reziduum \mathbf{r}^{k+1} je ortogonální k $\mathbf{r}^0, \mathbf{r}^1, \dots, \mathbf{r}^k$.

Dk.

- Vyjádříme \mathbf{r}^i jako

$$\mathbf{r}^i = \mathbf{d}^i + \sum_{j=0}^{i-1} \beta_{i,j} \mathbf{d}^j.$$

- Pak pro všechna $i \leq k$ platí:

$$(\mathbf{r}^{k+1})^T \mathbf{r}^i = (\mathbf{r}^{k+1})^T (\mathbf{d}^i + \sum_{j=0}^{i-1} \beta_{i,j} \mathbf{d}^j) = (\mathbf{r}^{k+1})^T \mathbf{d}^i + \sum_{j=0}^{i-1} \beta_{i,j} (\mathbf{r}^{k+1})^T \mathbf{d}^j = 0.$$



Lemma

Nechť je dána množina reziduí $\{\mathbf{r}^i\}_{i=0}^{n-1}$ a sdružených směrů $\{\mathbf{d}^i\}_{i=0}^{n-1}$. Potom platí:

$$j < k : (\mathbf{r}^{k+1})^T A \mathbf{d}^j = 0$$

$$j = k : (\mathbf{r}^{k+1})^T A \mathbf{d}^j \neq 0$$

Lemma

Nechť je dána množina reziduí $\{\mathbf{r}^i\}_{i=0}^{n-1}$ a sdružených směrů $\{\mathbf{d}^i\}_{i=0}^{n-1}$. Potom platí:

$$j < k : (\mathbf{r}^{k+1})^T A \mathbf{d}^j = 0$$

$$j = k : (\mathbf{r}^{k+1})^T A \mathbf{d}^j \neq 0$$

Důkaz

- Pro reziduum platí

$$\mathbf{r}^{j+1} = \mathbf{b} - A\mathbf{x}^{j+1} = \mathbf{b} - A(\mathbf{x}^j + \alpha_j \mathbf{d}^j) = \mathbf{r}^j - \alpha_j A \mathbf{d}^j$$

Lemma

Nechť je dána množina reziduí $\{\mathbf{r}^i\}_{i=0}^{n-1}$ a sdružených směrů $\{\mathbf{d}^i\}_{i=0}^{n-1}$. Potom platí:

$$j < k : (\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^j = 0$$

$$j = k : (\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^j \neq 0$$

Důkaz

- Pro reziduum platí

$$\mathbf{r}^{j+1} = \mathbf{b} - \mathbf{A} \mathbf{x}^{j+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}^j + \alpha_j \mathbf{d}^j) = \mathbf{r}^j - \alpha_j \mathbf{A} \mathbf{d}^j$$

- Odtud

$$\mathbf{A} \mathbf{d}^j = -\frac{1}{\alpha_j}(\mathbf{r}^{j+1} - \mathbf{r}^j)$$

Lemma

Nechť je dána množina reziduí $\{\mathbf{r}^i\}_{i=0}^{n-1}$ a sdružených směrů $\{\mathbf{d}^i\}_{i=0}^{n-1}$. Potom platí:

$$j < k : (\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^j = 0$$

$$j = k : (\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^j \neq 0$$

Důkaz

- Pro reziduum platí

$$\mathbf{r}^{j+1} = \mathbf{b} - \mathbf{A} \mathbf{x}^{j+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}^j + \alpha_j \mathbf{d}^j) = \mathbf{r}^j - \alpha_j \mathbf{A} \mathbf{d}^j$$

- Odtud

$$\mathbf{A} \mathbf{d}^j = -\frac{1}{\alpha_j}(\mathbf{r}^{j+1} - \mathbf{r}^j)$$

a

$$(\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^j = (\mathbf{r}^{k+1})^T \left(\frac{1}{\alpha_j}(\mathbf{r}^j - \mathbf{r}^{j+1}) \right) = \frac{1}{\alpha_j}(\mathbf{r}^{k+1})^T \mathbf{r}^j - \frac{1}{\alpha_j}(\mathbf{r}^{k+1})^T \mathbf{r}^{j+1}$$

Lemma

Nechť je dána množina reziduí $\{\mathbf{r}^i\}_{i=0}^{n-1}$ a sdružených směrů $\{\mathbf{d}^i\}_{i=0}^{n-1}$. Potom platí:

$$j < k : (\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^j = 0$$

$$j = k : (\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^j \neq 0$$

Důkaz

- Pro reziduum platí

$$\mathbf{r}^{j+1} = \mathbf{b} - \mathbf{A} \mathbf{x}^{j+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}^j + \alpha_j \mathbf{d}^j) = \mathbf{r}^j - \alpha_j \mathbf{A} \mathbf{d}^j$$

- Odtud

$$\mathbf{A} \mathbf{d}^j = -\frac{1}{\alpha_j} (\mathbf{r}^{j+1} - \mathbf{r}^j)$$

a

$$(\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^j = (\mathbf{r}^{k+1})^T \left(\frac{1}{\alpha_j} (\mathbf{r}^j - \mathbf{r}^{j+1}) \right) = \frac{1}{\alpha_j} (\mathbf{r}^{k+1})^T \mathbf{r}^j - \frac{1}{\alpha_j} (\mathbf{r}^{k+1})^T \mathbf{r}^{j+1}$$

- Pro $j < k$ je tento výraz díky ortogonalitě reziduí nulový. Pro $j = k$ dostaneme

$$(\mathbf{r}^{k+1})^T \mathbf{A} \mathbf{d}^k = \frac{1}{\alpha_k} (\mathbf{r}^{k+1})^T \mathbf{r}^k - \frac{1}{\alpha_k} (\mathbf{r}^{k+1})^T \mathbf{r}^{k+1} = -\frac{1}{\alpha_k} (\mathbf{r}^{k+1})^T \mathbf{r}^{k+1}.$$

- Zjistili jsme tedy, že pro $j = 0, \dots, k - 1$ jsou čitatele v sumě

$$\mathbf{d}^{k+1} = \mathbf{r}^{k+1} - \sum_{j=0}^k \frac{(\mathbf{d}^j)^T \mathbf{A} \mathbf{r}^{k+1}}{(\mathbf{d}^j)^T \mathbf{A} \mathbf{d}^j} \mathbf{d}^j.$$

rovni nule.

- Předpis se tedy zjednoduší na

$$\mathbf{d}^{k+1} = \mathbf{r}^{k+1} - \underbrace{\frac{(\mathbf{d}^k)^T \mathbf{A} \mathbf{r}^{k+1}}{(\mathbf{d}^k)^T \mathbf{A} \mathbf{d}^k}}_{=\beta_k} \mathbf{d}^k.$$

- Protože všechny ostatní koeficienty v dané sumě jsou nulové, budeme pro jednoduchost psát místo $\beta_{k,k}$ jen β_k .

- Využijme rovnosti $\mathbf{Ad}^k = \frac{1}{\alpha_k}(\mathbf{r}^k - \mathbf{r}^{k+1})$ a upravme čitatele ve výrazu β_k

$$(\mathbf{r}^{k+1})^T \mathbf{Ad}^k = \frac{1}{\alpha_k} (\mathbf{r}^{k+1})^T (\mathbf{r}^k - \mathbf{r}^{k+1}) = -\frac{1}{\alpha_k} (\mathbf{r}^{k+1})^T \mathbf{r}^{k+1}.$$

- Využijme rovnosti $A\mathbf{d}^k = \frac{1}{\alpha_k}(\mathbf{r}^k - \mathbf{r}^{k+1})$ a upravme čitatele ve výrazu β_k

$$(\mathbf{r}^{k+1})^T A\mathbf{d}^k = \frac{1}{\alpha_k}(\mathbf{r}^{k+1})^T(\mathbf{r}^k - \mathbf{r}^{k+1}) = -\frac{1}{\alpha_k}(\mathbf{r}^{k+1})^T \mathbf{r}^{k+1}.$$

a jmenovatele

$$(\mathbf{d}^k)^T A\mathbf{d}^k = (\mathbf{r}^k - \beta_{k-1}\mathbf{d}^{k-1})^T A\mathbf{d}^k = \frac{1}{\alpha_k}(\mathbf{r}^k)^T(\mathbf{r}^k - \mathbf{r}^{k+1}) = \frac{1}{\alpha_k}(\mathbf{r}^k)^T \mathbf{r}^k.$$

- Využijme rovnosti $A\mathbf{d}^k = \frac{1}{\alpha_k}(\mathbf{r}^k - \mathbf{r}^{k+1})$ a upravme čitatele ve výrazu β_k

$$(\mathbf{r}^{k+1})^T A\mathbf{d}^k = \frac{1}{\alpha_k}(\mathbf{r}^{k+1})^T (\mathbf{r}^k - \mathbf{r}^{k+1}) = -\frac{1}{\alpha_k}(\mathbf{r}^{k+1})^T \mathbf{r}^{k+1}.$$

a jmenovatele

$$(\mathbf{d}^k)^T A\mathbf{d}^k = (\mathbf{r}^k - \beta_{k-1}\mathbf{d}^{k-1})^T A\mathbf{d}^k = \frac{1}{\alpha_k}(\mathbf{r}^k)^T (\mathbf{r}^k - \mathbf{r}^{k+1}) = \frac{1}{\alpha_k}(\mathbf{r}^k)^T \mathbf{r}^k.$$

- Po dosazení do předpisu pro β_k dostaneme

$$\beta_k = -\frac{(\mathbf{r}^{k+1})^T \mathbf{r}^{k+1}}{(\mathbf{r}^k)^T \mathbf{r}^k}$$

- Podobně můžeme upravit předpis pro α_k

$$\alpha_k = \frac{(\mathbf{d}^k)^T \mathbf{r}^k}{(\mathbf{d}^k)^T A\mathbf{d}^k} = \frac{(\mathbf{r}^k)^T \mathbf{r}^k}{(\mathbf{d}^k)^T A\mathbf{d}^k}.$$

```

function conjugate_gradient( $A, b, x^0$ )
     $d^0 = r^0 = b - Ax^0$ 
     $k = 0$ 
    while  $\|r^k\| / \|r^0\| > \varepsilon$  do
         $\alpha_k = \frac{(r^k)^T r^k}{(d^k)^T A d^k}$ 
         $x^{k+1} = x^k + \alpha_k d^k$ 
         $r^{k+1} = r^k - \alpha_k A r^k$ 
         $\beta_k = \frac{(r^{k+1})^T r^{k+1}}{(r^k)^T r^k}$ 
         $d^{k+1} = r^{k+1} + \beta_k d^k$ 
         $k = k + 1$ 
    end while
end function

```

- Chybu můžeme odhadnout pomocí vztahů

$$\|\mathbf{e}^{k+1}\|_A \leq \frac{\kappa(A) - 1}{\kappa(A) + 1} \|\mathbf{e}^k\|_A$$

a

$$\|\mathbf{e}^k\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|\mathbf{e}^0\|_A.$$

- Chybu můžeme odhadnout pomocí vztahů

$$\|e^{k+1}\|_A \leq \frac{\kappa(A) - 1}{\kappa(A) + 1} \|e^k\|_A$$

a

$$\|e^k\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|e^0\|_A.$$

- Můžeme také odhadnout maximální počet iterací nutných k dosažení relativní přesnosti ε (tedy $\|e^k\| \leq \varepsilon \|e^0\|$):

$$k \leq \lceil \frac{1}{2} \sqrt{\kappa(A)} \ln \frac{2}{\varepsilon} \rceil.$$

- Chybu můžeme odhadnout pomocí vztahů

$$\|e^{k+1}\|_A \leq \frac{\kappa(A) - 1}{\kappa(A) + 1} \|e^k\|_A$$

a

$$\|e^k\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|e^0\|_A.$$


- Můžeme také odhadnout maximální počet iterací nutných k dosažení relativní přesnosti ε (tedy $\|e^k\| \leq \varepsilon \|e^0\|$):

$$k \leq \lceil \frac{1}{2} \sqrt{\kappa(A)} \ln \frac{2}{\varepsilon} \rceil.$$

- Porovnejme to s metodou největšího spádu, pro kterou platí

$$k \leq \lceil \frac{1}{2} \kappa(A) \ln \frac{1}{\varepsilon} \rceil.$$

- Porovnejme maximální počet iterací nutných k dosažení dané relativní přesnosti pomocí metody největšího spádu a metody sdružených gradientů.



Na závěr poznamenejme, že metoda sdružených gradientů patří mezi tzv. Krylovovské metody. Tyto metody generují posloupnost Krylovových podprostorů ve tvaru $\mathcal{K}^k(\mathbf{A}, \mathbf{b}) = \text{span} \{ \mathbf{b}, \mathbf{A}\mathbf{b}, \mathbf{A}^2\mathbf{b}, \dots, \mathbf{A}^k\mathbf{b} \}$ a v každé iteraci minimalizují chybu v energetické normě na daném podprostoru, tedy

$$\mathbf{x}^{k+1} = \arg \min_{\bar{\mathbf{x}} \in \mathbf{x}^0 + \mathcal{K}^k(\mathbf{A}, \mathbf{r}^0)} \|\mathbf{x} - \bar{\mathbf{x}}\|_{\mathbf{A}},$$

kde \mathbf{x} je přesné řešení.

Předpodmínění

- Rychlost konvergence iteračních metod závisí na čísle podmíněnosti $\kappa(A)$ matice soustavy.

Předpodmínění

- Rychlost konvergence iteračních metod závisí na čísle podmíněnosti $\kappa(A)$ matice soustavy.
- Cílem předpodmínění je snížení čísla podmíněnosti soustavy a tedy i počtu iterací potřebných k řešení.

Předpodmínění

- Rychlost konvergence iteračních metod závisí na čísle podmíněnosti $\kappa(A)$ matice soustavy.
- Cílem předpodmínění je snížení čísla podmíněnosti soustavy a tedy i počtu iterací potřebných k řešení.
- Buď M taková matice, že platí $\kappa(M^{-1}A) \ll \kappa(A)$, pak místo původní soustavy

$$Ax = b$$

můžeme řešit předpodmíněnou soustavu

$$M^{-1}Ax = M^{-1}b.$$

Předpodmínění

- Rychlost konvergence iteračních metod závisí na čísle podmíněnosti $\kappa(A)$ matice soustavy.
- Cílem předpodmínění je snížení čísla podmíněnosti soustavy a tedy i počtu iterací potřebných k řešení.
- Buď M taková matice, že platí $\kappa(M^{-1}A) \ll \kappa(A)$, pak místo původní soustavy

$$Ax = b$$

můžeme řešit předpodmíněnou soustavu

$$M^{-1}Ax = M^{-1}b.$$

- Matici M nazýváme levým předpodmiňovačem.

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.
- Sestavme Choleského rozklad $M = LL^T$ a využijme toho, že $M^{-1}A$ a $L^{-1}AL^{-T}$ mají stejná vlastní čísla (tzn. stejné číslo podmíněnosti)

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.
- Sestavme Choleského rozklad $M = LL^T$ a využijme toho, že $M^{-1}A$ a $L^{-1}AL^{-T}$ mají stejná vlastní čísla (tzn. stejné číslo podmíněnosti)– je-li v vlastní vektor matice $M^{-1}A$ s vlastním číslem λ , pak $L^T v$ je vlastní vektor $L^{-1}AL^{-T}$ se stejným vlastním číslem λ :

$$(L^{-1}AL^{-T})(L^T v)$$

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.
- Sestavme Choleského rozklad $M = LL^T$ a využijme toho, že $M^{-1}A$ a $L^{-1}AL^{-T}$ mají stejná vlastní čísla (tzn. stejné číslo podmíněnosti)– je-li v vlastní vektor matice $M^{-1}A$ s vlastním číslem λ , pak $L^T v$ je vlastní vektor $L^{-1}AL^{-T}$ se stejným vlastním číslem λ :

$$(L^{-1}AL^{-T})(L^T v) = L^{-1}A \underbrace{L^{-T}L^T}_{=I} v$$

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.
- Sestavme Choleského rozklad $M = LL^T$ a využijme toho, že $M^{-1}A$ a $L^{-1}AL^{-T}$ mají stejná vlastní čísla (tzn. stejné číslo podmíněnosti)– je-li v vlastní vektor matice $M^{-1}A$ s vlastním číslem λ , pak $L^T v$ je vlastní vektor $L^{-1}AL^{-T}$ se stejným vlastním číslem λ :

$$(L^{-1}AL^{-T})(L^T v) = L^{-1}A \underbrace{L^{-T}L^T}_{=I} v = L^{-1}Av$$

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.
- Sestavme Choleského rozklad $M = LL^T$ a využijme toho, že $M^{-1}A$ a $L^{-1}AL^{-T}$ mají stejná vlastní čísla (tzn. stejné číslo podmíněnosti)– je-li v vlastní vektor matice $M^{-1}A$ s vlastním číslem λ , pak $L^T v$ je vlastní vektor $L^{-1}AL^{-T}$ se stejným vlastním číslem λ :

$$(L^{-1}AL^{-T})(L^T v) = L^{-1}A \underbrace{L^{-T}L^T}_{=I} v = L^{-1}Av = (\underbrace{L^T L^{-T}}_{=I}) L^{-1}Av$$

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.
- Sestavme Choleského rozklad $M = LL^T$ a využijme toho, že $M^{-1}A$ a $L^{-1}AL^{-T}$ mají stejná vlastní čísla (tzn. stejné číslo podmíněnosti)– je-li v vlastní vektor matice $M^{-1}A$ s vlastním číslem λ , pak $L^T v$ je vlastní vektor $L^{-1}AL^{-T}$ se stejným vlastním číslem λ :

$$\begin{aligned}
 (L^{-1}AL^{-T})(L^T v) &= L^{-1}A \underbrace{L^{-T}L^T}_{=I} v = L^{-1}Av = \underbrace{(L^T L^{-T})}_{=I} L^{-1}Av \\
 &= L^T \underbrace{L^{-T}L^{-1}}_{=M^{-1}} Av
 \end{aligned}$$

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.
- Sestavme Choleského rozklad $M = LL^T$ a využijme toho, že $M^{-1}A$ a $L^{-1}AL^{-T}$ mají stejná vlastní čísla (tzn. stejné číslo podmíněnosti)– je-li v vlastní vektor matice $M^{-1}A$ s vlastním číslem λ , pak $L^T v$ je vlastní vektor $L^{-1}AL^{-T}$ se stejným vlastním číslem λ :

$$\begin{aligned}
 (L^{-1}AL^{-T})(L^T v) &= L^{-1}A \underbrace{L^{-T}L^T}_{=I} v = L^{-1}Av = (\underbrace{L^T L^{-T}}_{=I}) L^{-1}Av \\
 &= L^T \underbrace{L^{-T}L^{-1}}_{=M^{-1}} Av = L^T \underbrace{M^{-1}Av}_{=\lambda v}
 \end{aligned}$$

- Je-li A symetrická pozitivně definitní je výhodné použít např. metodu největšího spádu nebo metodu sdružených gradientů.
- V takovém případě chceme, aby i předpodmiňovač M byl SPD matice (poté je i M^{-1} SPD).
- Součin $M^{-1}A$ nemusí obecně být SPD matice \Rightarrow na systém $M^{-1}Ax = M^{-1}b$ nemůžeme použít metodu největšího spádu ani sdružených gradientů.
- Sestavme Choleského rozklad $M = LL^T$ a využijme toho, že $M^{-1}A$ a $L^{-1}AL^{-T}$ mají stejná vlastní čísla (tzn. stejné číslo podmíněnosti) – je-li v vlastní vektor matice $M^{-1}A$ s vlastním číslem λ , pak $L^T v$ je vlastní vektor $L^{-1}AL^{-T}$ se stejným vlastním číslem λ :

$$\begin{aligned}
 (L^{-1}AL^{-T})(L^T v) &= L^{-1}A \underbrace{L^{-T}L^T}_{=I} v = L^{-1}Av = (\underbrace{L^T L^{-T}}_{=I}) L^{-1}Av \\
 &= L^T \underbrace{L^{-T}L^{-1}}_{=M^{-1}} Av = L^T \underbrace{M^{-1}Av}_{=\lambda v} = \lambda L^T v
 \end{aligned}$$

- Přenásobme nyní původní soustavu $Ax = b$ zleva maticí L^{-1} :

$$L^{-1}Ax = L^{-1}b$$

- Přenásobme nyní původní soustavu $Ax = b$ zleva maticí L^{-1} :

$$L^{-1}Ax = L^{-1}b$$

- Abychom zachovali symetrii a pozitivní definitnost, musíme matici A přenásobit L^{-T} zprava.

$$L^{-1}A \underbrace{L^{-T}L^T}_{=I} x = L^{-1}b.$$

- Přenásobme nyní původní soustavu $Ax = b$ zleva maticí L^{-1} :

$$L^{-1}Ax = L^{-1}b$$

- Abychom zachovali symetrii a pozitivní definitnost, musíme matici A přenásobit L^{-T} zprava.

$$L^{-1}A \underbrace{L^{-T}L^T}_{=I} x = L^{-1}b.$$

- Místo původní soustavy $Ax = b$ a místo soustavy $M^{-1}Ax = M^{-1}b$ řešme ekvivalentní systém

$$(L^{-1}AL^{-T})(L^T x) = L^{-1}b.$$

- Přenásobme nyní původní soustavu $Ax = b$ zleva maticí L^{-1} :

$$L^{-1}Ax = L^{-1}b$$

- Abychom zachovali symetrii a pozitivní definitnost, musíme matici A přenásobit L^{-T} zprava.

$$L^{-1}A \underbrace{L^{-T}L^T}_{=I}x = L^{-1}b.$$

- Místo původní soustavy $Ax = b$ a místo soustavy $M^{-1}Ax = M^{-1}b$ řešme ekvivalentní systém

$$(L^{-1}AL^{-T})(L^Tx) = L^{-1}b.$$

- Zaved'me značení $\hat{A} = L^{-1}AL^{-T}$, $\hat{x} = L^Tx$, $\hat{b} = L^{-1}b$. Soustavu pak můžeme zapsat jako

$$\hat{A}\hat{x} = \hat{b}. \tag{1}$$

- Matice $\hat{A} = L^{-1}AL^{-T}$ je symetrická a pozitivně definitní, k řešení tedy můžeme použít metodu největšího spádu či metodu sdružených gradientů.

- Po nalezení \hat{x} získáme řešení původní soustavy jako $x = L^{-T}\hat{x}$.

- Nevýhoda předchozího přístupu – potřebujeme znát rozklad $M = LL^T$.

- Nevýhoda předchozího přístupu – potřebujeme znát rozklad $M = LL^T$.
- Vhodnou manipulací s předpisy iteračních metod se této nutnosti zbavíme.

- Nevýhoda předchozího přístupu – potřebujeme znát rozklad $M = LL^T$.
- Vhodnou manipulací s předpisy iteračních metod se této nutnosti zbavíme.
- Aplikujme např. předpis Richardsonovy metody na soustavu $\hat{A}\hat{x} = \hat{b}$:

$$\hat{x}^{k+1} = \hat{x}^k + \omega(\hat{b} - \hat{A}\hat{x}^k),$$

- Nevýhoda předchozího přístupu – potřebujeme znát rozklad $M = LL^T$.
- Vhodnou manipulací s předpisem iteračních metod se této nutnosti zbavíme.
- Aplikujme např. předpis Richardsonovy metody na soustavu $\hat{A}\hat{x} = \hat{b}$:

$$\hat{x}^{k+1} = \hat{x}^k + \omega(\hat{b} - \hat{A}\hat{x}^k),$$

Tedy

$$L^T x^{k+1} = L^T x^k + \omega(L^{-1}b - L^{-1}AL^{-T}L^T x^k).$$

Přenásobme zleva maticí L^{-T} :

$$L^{-T}L^T x^{k+1} = L^{-T}L^T x^k + \omega(L^{-T}L^{-1}b - L^{-T}L^{-1}AL^{-T}L^T x^k).$$

- Nevýhoda předchozího přístupu – potřebujeme znát rozklad $M = LL^T$.
- Vhodnou manipulací s předpisem iteračních metod se této nutnosti zbavíme.
- Aplikujme např. předpis Richardsonovy metody na soustavu $\hat{A}\hat{x} = \hat{b}$:

$$\hat{x}^{k+1} = \hat{x}^k + \omega(\hat{b} - \hat{A}\hat{x}^k),$$

Tedy

$$L^T x^{k+1} = L^T x^k + \omega(L^{-1}b - L^{-1}AL^{-T}L^T x^k).$$

Přenásobme zleva maticí L^{-T} :

$$L^{-T}L^T x^{k+1} = L^{-T}L^T x^k + \omega(L^{-T}L^{-1}b - L^{-T}L^{-1}AL^{-T}L^T x^k).$$

\Downarrow

$$x^{k+1} = x^k + \omega M^{-1}(b - Ax^k).$$

- Jak zvolit M :

- inverze M by měla aproximovat inverzi A ($M^{-1} \approx A^{-1}$),
- řešení soustavy s M by mělo být snadné a efektivní,
- pokud je matice A symetrická a pozitivně definitní, měl by i předpodmiňovač být symetrický pozitivně definitní.

- Jak zvolit M :
 - inverze M by měla aproximovat inverzi A ($M^{-1} \approx A^{-1}$),
 - řešení soustavy s M by mělo být snadné a efektivní,
 - pokud je matice A symetrická a pozitivně definitní, měl by i předpodmiňovač být symetrický pozitivně definitní.
- $M = A - v$ v takovém případě inverze M aproximuje inverzi A přesně, ale aplikace samotného předpodmínění je stejně náročná jako řešení původní úlohy;
- $M = I - v$ v tomto případě je sice aplikace předpodmiňovače triviální, nedosáhneme ale žádného zlepšení čísla podmíněnosti (získáme původní nepředpodmíněný algoritmus).

- diagonální předpodmiňovač – volíme $M = \text{diag } A$. V tomto případě je výpočet inverze M velmi snadný. Tento předpodmiňovač je efektivní např. pro soustavy s diagonálně dominantní maticí.
- neúplný LU/Choleského rozklad – je vhodný pro soustavy s řídkou maticí. Problémem klasického LU/Choleského rozkladu je, že přestože je matice A řídká, mohou být její faktory L, U plné nebo více zaplněné. Princip neúplného LU/Choleského rozkladu je jednoduchý - použijeme stejný algoritmus jako u klasického LU/Choleského rozkladu, ale nenulový prvek do matice L nebo U uložíme pouze tehdy, existuje-li nenulový prvek na stejné pozici v rozkládané matici A . Dostaneme neúplné faktory \tilde{L}, \tilde{U} a příslušné předpodmiňovače definujeme jako $M = \tilde{L}\tilde{U}$ nebo $M = \tilde{L}\tilde{L}^T$. Řešit soustavu s M je pak snadné, protože známe její rozklad na součin trojúhelníkových matic a můžeme použít dopřednou a zpětnou substituci.

Děkuji za pozornost

Michal Merta

VŠB – Technická univerzita Ostrava

michal.merta@vsb.cz

6. dubna 2023