

# Numerická lineární algebra 1

## Aplikace QR rozkladu, mocnná metoda

Michal Merta

VŠB – Technická univerzita Ostrava

michal.merta@vsb.cz

27. dubna 2023

- 1 Aplikace QR rozkladu
  - Řešení problému nejmenších čtverců
  - Spektrální rozklad

- 2 Mocninná metoda

# Metoda nejmenších čtverců – motivační příklad



- Experimentálně jsme zjistili, že tlak v automatickém espresso kávovaru závisí mj. na hrubosti mletí kávových zrn. Závislost můžeme zakreslit do grafu.

# Metoda nejmenších čtverců – motivační příklad



- Experimentálně jsme zjistili, že tlak v automatickém espresso kávovaru závisí mj. na hrubosti mletí kávových zrn. Závislost můžeme zakreslit do grafu.
- Graf naznačuje lineární závislost.

# Metoda nejmenších čtverců – motivační příklad



- Experimentálně jsme zjistili, že tlak v automatickém espresso kávovaru závisí mj. na hrubosti mletí kávových zrn. Závislost můžeme zakreslit do grafu.
- Graf naznačuje lineární závislost.
- Měření je zatížené chybou – nenalezneme žádnou lineární funkci, která prochází všemi body.

- Nedokážeme nalézt funkci  $p(x) = c_1 + c_2x$ , která prochází všemi body.

- Nedokážeme nalézt funkci  $p(x) = c_1 + c_2x$ , která prochází všemi body.
- V případě dvou měření  $(x_1, y_1), (x_2, y_2)$  bychom získali bychom soustavu dvou rovnic o dvou neznámých

$$y_1 = c_1 + c_2x_1$$

$$y_2 = c_1 + c_2x_2,$$



- Nedokážeme nalézt funkci  $p(x) = c_1 + c_2x$ , která prochází všemi body.
- V případě dvou měření  $(x_1, y_1), (x_2, y_2)$  bychom získali bychom soustavu dvou rovnic o dvou neznámých

$$y_1 = c_1 + c_2x_1$$

$$y_2 = c_1 + c_2x_2,$$

- V našem případě ale získáme pět rovnic o dvou neznámých – přeurčený systém, který obecně nemusí mít řešení.

- Nedokážeme nalézt funkci  $p(x) = c_1 + c_2x$ , která prochází všemi body.
- V případě dvou měření  $(x_1, y_1), (x_2, y_2)$  bychom získali bychom soustavu dvou rovnic o dvou neznámých

$$y_1 = c_1 + c_2x_1$$

$$y_2 = c_1 + c_2x_2,$$

- V našem případě ale získáme pět rovnic o dvou neznámých – přeurčený systém, který obecně nemusí mít řešení.
- Můžeme se ale pokusit nalézt přímu  $p$ , která sice neprochází všemi body, ale chyba, které se dopouštíme, je v jistém smyslu minimální.



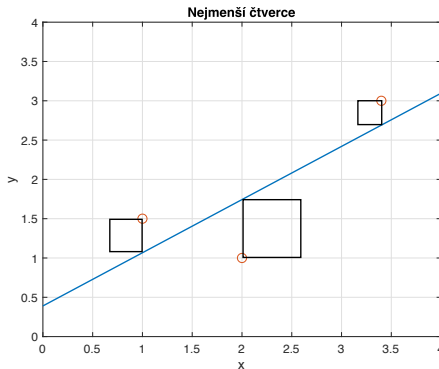
- Hledáme lineární funkci  $p$ , která nemusí procházet danými body, ale chyba, které se dopouštíme, je minimální ve smyslu nejmenších čtverců.

- Hledáme lineární funkci  $p$ , která nemusí procházet danými body, ale chyba, které se dopouštíme, je minimální ve smyslu nejmenších čtverců.
- Chceme, aby součet druhých mocnin (čtverců) odchylek hledané funkce od naměřených hodnot byl co nejmenší:

$$\min_{p \text{ lineární}} \sum_{j=1}^m (p(x_j) - y_j)^2$$

- Hledáme lineární funkci  $p$ , která nemusí procházet danými body, ale chyba, které se dopouštíme, je minimální ve smyslu nejmenších čtverců.
- Chceme, aby součet druhých mocnin (čtverců) odchylek hledané funkce od naměřených hodnot byl co nejmenší:

$$\min_{p \text{ lineární}} \sum_{j=1}^m (p(x_j) - y_j)^2$$



- Dosadíme-li  $p(x_j) = c_1 + c_2 x_j$  do  $\min_{p \text{ lineární}} \sum_{j=1}^m (p(x_j) - y_j)^2$ , můžeme minimalizační problém přepsat na

$$\min_{c_1, c_2 \in \mathbb{R}} \left\| \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_{m-1} \\ 1 & x_m \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} - \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{m-1} \\ y_m \end{bmatrix} \right\|^2$$

- Dosadíme-li  $p(x_j) = c_1 + c_2 x_j$  do  $\min_{p \text{ lineární}} \sum_{j=1}^m (p(x_j) - y_j)^2$ , můžeme minimalizační problém přepsat na

$$\min_{c_1, c_2 \in \mathbb{R}} \left\| \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_{m-1} \\ 1 & x_m \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} - \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{m-1} \\ y_m \end{bmatrix} \right\|^2$$

- Problém nejmenších čtverců nemusí vznikat pouze aproximací funkce polynomem – obecně, máme-li  $A \in \mathbb{R}^{m \times n}$ ,  $\mathbf{c} \in \mathbb{R}^n$  a  $\mathbf{y} \in \mathbb{R}^m$ ,  $n < m$  a chceme-li aproximovat řešení přeřčeného systému  $A\mathbf{c} = \mathbf{y}$ , získáme problém

$$\min_{\mathbf{c} \in \mathbb{R}^n} \|A\mathbf{c} - \mathbf{y}\|.$$

- Dosadíme-li  $p(x_j) = c_1 + c_2 x_j$  do  $\min_p \text{lineární} \sum_{j=1}^m (p(x_j) - y_j)^2$ , můžeme minimalizační problém přepsat na

$$\min_{c_1, c_2 \in \mathbb{R}} \left\| \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ & \vdots \\ 1 & x_{m-1} \\ 1 & x_m \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} - \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{m-1} \\ y_m \end{bmatrix} \right\|^2$$

- Problém nejmenších čtverců nemusí vznikat pouze aproximací funkce polynomem – obecně, máme-li  $A \in \mathbb{R}^{m \times n}$ ,  $\mathbf{c} \in \mathbb{R}^n$  a  $\mathbf{y} \in \mathbb{R}^m$ ,  $n < m$  a chceme-li aproximovat řešení přeřčeného systému  $A\mathbf{c} = \mathbf{y}$ , získáme problém

$$\min_{\mathbf{c} \in \mathbb{R}^n} \|A\mathbf{c} - \mathbf{y}\|.$$

- Tento problém můžeme řešit pomocí QR rozkladu.



- Hledejme tedy řešení  $\min_{c \in \mathbb{R}^m} \|Ac - y\|$  pomocí QR rozkladu.

- Hledejme tedy řešení  $\min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\|$  pomocí QR rozkladu.
- Předpokládejme, že známe úplný QR rozklad  $\mathbf{A} = \mathbf{Q}\mathbf{R}$ , kde

$$\hat{\mathbf{R}} = \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix}$$

a  $\mathbf{Q} \in \mathbb{R}^{m \times m}$ ,  $\mathbf{R} \in \mathbb{R}^{n \times n}$ ,  $\mathbf{O} \in \mathbb{R}^{(m-n) \times n}$ .

- Hledejme tedy řešení  $\min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\|$  pomocí QR rozkladu.
- Předpokládejme, že známe úplný QR rozklad  $\mathbf{A} = \mathbf{Q}\hat{\mathbf{R}}$ , kde

$$\hat{\mathbf{R}} = \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix}$$

a  $\mathbf{Q} \in \mathbb{R}^{m \times m}$ ,  $\mathbf{R} \in \mathbb{R}^{n \times n}$ ,  $\mathbf{O} \in \mathbb{R}^{(m-n) \times n}$ . Pak

$$\min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\| = \min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{Q}\hat{\mathbf{R}}\mathbf{c} - \mathbf{y}\|$$

- Hledejme tedy řešení  $\min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\|$  pomocí QR rozkladu.
- Předpokládejme, že známe úplný QR rozklad  $\mathbf{A} = \mathbf{Q}\hat{\mathbf{R}}$ , kde

$$\hat{\mathbf{R}} = \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix}$$

a  $\mathbf{Q} \in \mathbb{R}^{m \times m}$ ,  $\mathbf{R} \in \mathbb{R}^{n \times n}$ ,  $\mathbf{O} \in \mathbb{R}^{(m-n) \times n}$ . Pak

$$\min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\| = \min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{Q}\hat{\mathbf{R}}\mathbf{c} - \mathbf{y}\| = \min_{\mathbf{c} \in \mathbb{R}^m} \|\underbrace{\mathbf{Q}^T \mathbf{Q}}_{=\mathbf{I}} \hat{\mathbf{R}}\mathbf{c} - \mathbf{Q}^T \mathbf{y}\|$$

- Hledejme tedy řešení  $\min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\|$  pomocí QR rozkladu.
- Předpokládejme, že známe úplný QR rozklad  $\mathbf{A} = \mathbf{Q}\mathbf{R}$ , kde

$$\hat{\mathbf{R}} = \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix}$$

a  $\mathbf{Q} \in \mathbb{R}^{m \times m}$ ,  $\mathbf{R} \in \mathbb{R}^{n \times n}$ ,  $\mathbf{O} \in \mathbb{R}^{(m-n) \times n}$ . Pak

$$\begin{aligned} \min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\| &= \min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{Q}\hat{\mathbf{R}}\mathbf{c} - \mathbf{y}\| = \min_{\mathbf{c} \in \mathbb{R}^m} \|\underbrace{\mathbf{Q}^T \mathbf{Q}}_{=\mathbf{I}} \hat{\mathbf{R}}\mathbf{c} - \mathbf{Q}^T \mathbf{y}\| \\ &= \min_{\mathbf{c} \in \mathbb{R}^m} \|\hat{\mathbf{R}}\mathbf{c} - \underbrace{\mathbf{Q}^T \mathbf{y}}_{\substack{\text{ozn. } \hat{\mathbf{y}}}}\| \end{aligned}$$

- Hledejme tedy řešení  $\min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\|$  pomocí QR rozkladu.
- Předpokládejme, že známe úplný QR rozklad  $\mathbf{A} = \mathbf{Q}\mathbf{R}$ , kde

$$\hat{\mathbf{R}} = \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix}$$

a  $\mathbf{Q} \in \mathbb{R}^{m \times m}$ ,  $\mathbf{R} \in \mathbb{R}^{n \times n}$ ,  $\mathbf{O} \in \mathbb{R}^{(m-n) \times n}$ . Pak

$$\begin{aligned} \min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\| &= \min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{Q}\hat{\mathbf{R}}\mathbf{c} - \mathbf{y}\| = \min_{\mathbf{c} \in \mathbb{R}^m} \|\underbrace{\mathbf{Q}^T \mathbf{Q}}_{=\mathbf{I}} \hat{\mathbf{R}}\mathbf{c} - \mathbf{Q}^T \mathbf{y}\| \\ &= \min_{\mathbf{c} \in \mathbb{R}^m} \|\hat{\mathbf{R}}\mathbf{c} - \underbrace{\mathbf{Q}^T \mathbf{y}}_{\substack{\text{ozn. } \hat{\mathbf{y}}}}\| = \min_{\mathbf{c} \in \mathbb{R}^m} \|\hat{\mathbf{R}}\mathbf{c} - \hat{\mathbf{y}}\| \end{aligned}$$

- Hledejme tedy řešení  $\min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\|$  pomocí QR rozkladu.
- Předpokládejme, že známe úplný QR rozklad  $\mathbf{A} = \mathbf{Q}\mathbf{R}$ , kde

$$\hat{\mathbf{R}} = \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix}$$

a  $\mathbf{Q} \in \mathbb{R}^{m \times m}$ ,  $\mathbf{R} \in \mathbb{R}^{n \times n}$ ,  $\mathbf{O} \in \mathbb{R}^{(m-n) \times n}$ . Pak

$$\begin{aligned} \min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{A}\mathbf{c} - \mathbf{y}\| &= \min_{\mathbf{c} \in \mathbb{R}^m} \|\mathbf{Q}\hat{\mathbf{R}}\mathbf{c} - \mathbf{y}\| = \min_{\mathbf{c} \in \mathbb{R}^m} \|\underbrace{\mathbf{Q}^T \mathbf{Q}}_{=\mathbf{I}} \hat{\mathbf{R}}\mathbf{c} - \mathbf{Q}^T \mathbf{y}\| \\ &= \min_{\mathbf{c} \in \mathbb{R}^m} \|\hat{\mathbf{R}}\mathbf{c} - \underbrace{\mathbf{Q}^T \mathbf{y}}_{\substack{= \text{ozn. } \hat{\mathbf{y}}}}\| = \min_{\mathbf{c} \in \mathbb{R}^m} \|\hat{\mathbf{R}}\mathbf{c} - \hat{\mathbf{y}}\| \end{aligned}$$

- Náš minimalizační problém jsme tedy převedli na

$$\min_{\mathbf{c} \in \mathbb{R}^n} \left\| \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix} \mathbf{c} - \begin{bmatrix} \hat{\mathbf{y}}(1:n) \\ \hat{\mathbf{y}}(n+1:m) \end{bmatrix} \right\|$$

## ■ Problém

$$\min_{\mathbf{c} \in \mathbb{R}^n} \left\| \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix} \mathbf{c} - \begin{bmatrix} \hat{\mathbf{y}}(1:n) \\ \hat{\mathbf{y}}(n+1:m) \end{bmatrix} \right\|$$

lze snadno vyřešit.



- Problém

$$\min_{\mathbf{c} \in \mathbb{R}^n} \left\| \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix} \mathbf{c} - \begin{bmatrix} \hat{\mathbf{y}}(1:n) \\ \hat{\mathbf{y}}(n+1:m) \end{bmatrix} \right\|$$

lze snadno vyřešit.

- Prvky na pozicích  $n+1:m$  výrazu uvnitř normy žádnou volbou  $\mathbf{c}$  neovlivníme.

- Problém

$$\min_{\mathbf{c} \in \mathbb{R}^n} \left\| \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix} \mathbf{c} - \begin{bmatrix} \hat{\mathbf{y}}(1:n) \\ \hat{\mathbf{y}}(n+1:m) \end{bmatrix} \right\|$$

lze snadno vyřešit.

- Prvky na pozicích  $n+1:m$  výrazu uvnitř normy žádnou volbou  $\mathbf{c}$  neovlivníme.
- Prvních  $n$  prvků můžeme vynulovat položíme-li

$$\mathbf{R}\mathbf{c} = \hat{\mathbf{y}}(1:n),$$

- Problém

$$\min_{\mathbf{c} \in \mathbb{R}^n} \left\| \begin{bmatrix} \mathbf{R} \\ \mathbf{O} \end{bmatrix} \mathbf{c} - \begin{bmatrix} \hat{\mathbf{y}}(1:n) \\ \hat{\mathbf{y}}(n+1:m) \end{bmatrix} \right\|$$

Ize snadno vyřešit.

- Prvky na pozicích  $n+1:m$  výrazu uvnitř normy žádnou volbou  $\mathbf{c}$  neovlivníme.
- Prvních  $n$  prvků můžeme vynulovat položíme-li

$$\mathbf{R}\mathbf{c} = \hat{\mathbf{y}}(1:n),$$

- Takto získáme hledané minimum.
- Jedná se o systém s horní trojúhelníkovou maticí – řešení získáme pomocí zpětné substituce.

## ■ Řešení motivačního problému



# Spektrální rozklad

## Definice

Bud'  $A \in \mathbb{R}^{n \times n}$ . Nenulový vektor  $v$  nazveme vlastním vektorem a  $\lambda$  nazveme příslušným vlastním číslem, platí-li

$$Av = \lambda v.$$

# Spektrální rozklad

## Definice

Bud'  $A \in \mathbb{R}^{n \times n}$ . Nenulový vektor  $\mathbf{v}$  nazveme vlastním vektorem a  $\lambda$  nazveme příslušným vlastním číslem, platí-li

$$A\mathbf{v} = \lambda\mathbf{v}.$$

- Rovnost můžeme zapsat maticově

$$AV = V\Lambda,$$
$$\Lambda = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix}, V = (\mathbf{v}_1 | \mathbf{v}_2 | \cdots | \mathbf{v}_n)$$

- spektrum – množina všech vlastních čísel

- V některých případech má  $A \in \mathbb{R}^{m \times m}$   $m$  lineárně nezávislých vlastních vektorů, které mohou být zvoleny tak, že jsou ortonormální.

- V některých případech má  $A \in \mathbb{R}^{m \times m}$   $m$  lineárně nezávislých vlastních vektorů, které mohou být zvoleny tak, že jsou ortonormální.
- V takovém případě existuje rozklad  $A = QDQ^T$



- V některých případech má  $A \in \mathbb{R}^{m \times m}$   $m$  lineárně nezávislých vlastních vektorů, které mohou být zvoleny tak, že jsou ortonormální.
- V takovém případě existuje rozklad  $A = QDQ^T$

### Věta

Bud'  $A \in \mathbb{R}^{m \times m}$  je reálná symetrická matice. Pak existují ortogonální matice  $Q$  a diagonální matice  $D$  takové, že

$$A = QDQ^T$$

Diagonální prvky  $D$  jsou vlastní čísla  $A$ , sloupce  $Q$  jsou ortonormální vlastní vektory  $A$ .

- V některých případech má  $A \in \mathbb{R}^{m \times m}$   $m$  lineárně nezávislých vlastních vektorů, které mohou být zvoleny tak, že jsou ortonormální.
- V takovém případě existuje rozklad  $A = QDQ^T$

### Věta

Bud'  $A \in \mathbb{R}^{m \times m}$  je reálná symetrická matice. Pak existují ortogonální matice  $Q$  a diagonální matice  $D$  takové, že

$$A = QDQ^T$$

Diagonální prvky  $D$  jsou vlastní čísla  $A$ , sloupce  $Q$  jsou ortonormální vlastní vektory  $A$ .

- Symetrické matice nejsou jediné, pro které existuje  $A = QDQ^T$ . Obecně platí:  $A$  je normální matice (tzn.  $A^T A = A A^T$ )  $\Leftrightarrow$  existuje  $A = QDQ^T$  (matice ale mohou být komplexní)

- Spektrální rozklad pomocí QR algoritmu
  - nápad: zkusme použít QR pomocí Householderových transformací pro vynulování nejen prvků ve sloupci, ale i v odpovídajícím řádku

- Spektrální rozklad pomocí QR algoritmu

- nápad: zkusme použít QR pomocí Householderových transformací pro vynulování nejen prvků ve sloupci, ale i v odpovídajícím řádku

$$A = Q_1 R_1, \quad Q_1^T A = R_1 = \begin{pmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \end{pmatrix}$$

## ■ Spektrální rozklad pomocí QR algoritmu

- nápad: zkusme použít QR pomocí Householderových transformací pro vynulování nejen prvků ve sloupci, ale i v odpovídajícím řádku

$$A = Q_1 R_1, \quad Q_1^T A = R_1 = \begin{pmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \end{pmatrix}$$

ale

$$Q_1^T A Q_1 = R_1 Q_1 = \begin{pmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \end{pmatrix}$$

- Násobení zleva opět vytvoří nenulové prvky i v prvním sloupci.

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$A_0 = A$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \end{aligned}$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$



- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned}A_0 &= A \\Q_k R_k &= A_{k-1} \\A_k &= R_k Q_k\end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$A_k = R_k Q_k$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$A_k = R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$A_k = R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k = Q_k^{-1} A_{k-1} Q_k$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$A_k = R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k = Q_k^{-1} A_{k-1} Q_k = Q_k^{-1} R_{k-1} Q_{k-1} Q_k$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$A_k = R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k = Q_k^{-1} A_{k-1} Q_k = Q_k^{-1} R_{k-1} Q_{k-1} Q_k = Q_k^{-1} Q_{k-1}^{-1} \underbrace{Q_{k-1} R_{k-1}}_{=A_{k-2}} Q_{k-1} Q_k$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$\begin{aligned} A_k &= R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k = Q_k^{-1} A_{k-1} Q_k = Q_k^{-1} R_{k-1} Q_{k-1} Q_k = Q_k^{-1} Q_{k-1}^{-1} \underbrace{Q_{k-1} R_{k-1}}_{=A_{k-2}} Q_{k-1} Q_k = \\ &= Q_k^T Q_{k-1}^T A_{k-2} Q_{k-1} Q_k \end{aligned}$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$\begin{aligned} A_k &= R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k = Q_k^{-1} A_{k-1} Q_k = Q_k^{-1} R_{k-1} Q_{k-1} Q_k = Q_k^{-1} Q_{k-1}^{-1} \underbrace{Q_{k-1} R_{k-1}}_{=A_{k-2}} Q_{k-1} Q_k = \\ &= Q_k^T Q_{k-1}^T A_{k-2} Q_{k-1} Q_k = \underbrace{Q_k^T Q_{k-1}^T \cdots Q_1^T}_{=\tilde{Q}_k^T} A \underbrace{Q_1 \cdots Q_{k-1} Q_k}_{=\tilde{Q}_k} \end{aligned}$$

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$\begin{aligned} A_k &= R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k = Q_k^{-1} A_{k-1} Q_k = Q_k^{-1} R_{k-1} Q_{k-1} Q_k = Q_k^{-1} Q_{k-1}^{-1} \underbrace{Q_{k-1} R_{k-1}}_{=A_{k-2}} Q_{k-1} Q_k = \\ &= Q_k^T Q_{k-1}^T A_{k-2} Q_{k-1} Q_k = \underbrace{Q_k^T Q_{k-1}^T \cdots Q_1^T}_{=\tilde{Q}_k^T} A \underbrace{Q_1 \cdots Q_{k-1} Q_k}_{=\tilde{Q}_k} \end{aligned}$$

tedy

$$A = \tilde{Q}_k A_k \tilde{Q}_k^T$$



- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$\begin{aligned} A_k &= R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k = Q_k^{-1} A_{k-1} Q_k = Q_k^{-1} R_{k-1} Q_{k-1} Q_k = Q_k^{-1} Q_{k-1}^{-1} \underbrace{Q_{k-1} R_{k-1}}_{=A_{k-2}} Q_{k-1} Q_k = \\ &= Q_k^T Q_{k-1}^T A_{k-2} Q_{k-1} Q_k = \underbrace{Q_k^T Q_{k-1}^T \cdots Q_1^T}_{=\tilde{Q}_k^T} A \underbrace{Q_1 \cdots Q_{k-1} Q_k}_{=\tilde{Q}_k} \end{aligned}$$

tedy

$$A = \tilde{Q}_k A_k \tilde{Q}_k^T$$

- Matice  $A$  a  $A_k$  jsou tedy podobné (takže mají stejná vlastní čísla)

- Lze ukázat, že následující postup (QR algoritmus) konverguje ke spektrálnímu rozkladu

$$\begin{aligned} A_0 &= A \\ Q_k R_k &= A_{k-1} \\ A_k &= R_k Q_k \end{aligned}$$

- V  $k$ . kroku tedy získáme:

$$\begin{aligned} A_k &= R_k Q_k = Q_k^{-1} \underbrace{Q_k R_k}_{=A_{k-1}} Q_k = Q_k^{-1} A_{k-1} Q_k = Q_k^{-1} R_{k-1} Q_{k-1} Q_k = Q_k^{-1} Q_{k-1}^{-1} \underbrace{Q_{k-1} R_{k-1}}_{=A_{k-2}} Q_{k-1} Q_k = \\ &= Q_k^T Q_{k-1}^T A_{k-2} Q_{k-1} Q_k = \underbrace{Q_k^T Q_{k-1}^T \cdots Q_1^T}_{=\tilde{Q}_k^T} A \underbrace{Q_1 \cdots Q_{k-1} Q_k}_{=\tilde{Q}_k} \end{aligned}$$

tedy

$$A = \tilde{Q}_k A_k \tilde{Q}_k^T$$

- Matice  $A$  a  $A_k$  jsou tedy podobné (takže mají stejná vlastní čísla)
- Pro  $k \rightarrow \infty$ :  $\tilde{Q}_k \rightarrow Q$ ,  $A_k \rightarrow D$  a platí  $A = QDQ^T$ , kde  $D$  je diagonální a  $Q$  je ortogonální matice tvořená vlastními vektory  $A$ .

```
function QDQT( $A \in \mathbb{R}^{m \times m}$ )  
  D=A  
  while norm(D - diag(diag(D)))>eps) do  
    [Qk, Rk] = qr(D)  
    D = Rk*Qk  
    Q=Q*Qk  
  end while  
end function
```

```

function QDQT( $A \in \mathbb{R}^{m \times m}$ )
  D=A
  while norm(D - diag(diag(D)))>eps) do
    [Qk, Rk] = qr(D)
    D = Rk*Qk
    Q=Q*Qk
  end while
end function

```

- Pozn. V případě nesymetrické matice konverguje  $A_k$  k trojúhelníkové matici s vlastními čísly na diagonále.

# Mocninná metoda

- Řešme tzv. částečný problém vlastních čísel (hledejme největší vlastní číslo v absolutní hodnotě).

## Definice

Bud'  $\lambda_1, \lambda_2, \dots, \lambda_n$  vlastní čísla čísla matice  $A \in \mathbb{R}^{n \times n}$ . Pak  $\lambda_1$  nazveme dominantním vlastním číslem  $A$ , platí-li

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|.$$

Vlastní vektor odpovídající dominantnímu vlastnímu číslu se nazývá dominantní vlastní vektor.

- K nalezení dominantního vlastního čísla a vektoru můžeme použít mocninnou metodu. Její princip je jednoduchý:

- K nalezení dominantního vlastního čísla a vektoru můžeme použít mocninnou metodu. Její princip je jednoduchý:
  - 1 Předpokládáme, že  $A$  má dominantní vlastní číslo.

- K nalezení dominantního vlastního čísla a vektoru můžeme použít mocninnou metodu. Její princip je jednoduchý:
  - 1 Předpokládáme, že  $A$  má dominantní vlastní číslo.
  - 2 Zvolíme nenulovou počáteční aproximaci  $x^0$  dominantního vlastního vektoru.



- K nalezení dominantního vlastního čísla a vektoru můžeme použít mocninnou metodu. Její princip je jednoduchý:
  - 1 Předpokládáme, že  $A$  má dominantní vlastní číslo.
  - 2 Zvolíme nenulovou počáteční aproximaci  $x^0$  dominantního vlastního vektoru.
  - 3 Vytvoříme posloupnost aproximací ve tvaru

$$x^1 = Ax^0$$

- K nalezení dominantního vlastního čísla a vektoru můžeme použít mocninnou metodu. Její princip je jednoduchý:
  - 1 Předpokládáme, že  $A$  má dominantní vlastní číslo.
  - 2 Zvolíme nenulovou počáteční aproximaci  $x^0$  dominantního vlastního vektoru.
  - 3 Vytvoříme posloupnost aproximací ve tvaru

$$x^1 = Ax^0$$

$$x^2 = Ax^1 = A(Ax^0) = A^2x^0$$

- K nalezení dominantního vlastního čísla a vektoru můžeme použít mocninnou metodu. Její princip je jednoduchý:
  - 1 Předpokládáme, že  $A$  má dominantní vlastní číslo.
  - 2 Zvolíme nenulovou počáteční aproximaci  $x^0$  dominantního vlastního vektoru.
  - 3 Vytvoříme posloupnost aproximací ve tvaru

$$x^1 = Ax^0$$

$$x^2 = Ax^1 = A(Ax^0) = A^2x^0$$

$$x^3 = Ax^2 = A(A(Ax^0)) = A^3x^0$$

- K nalezení dominantního vlastního čísla a vektoru můžeme použít mocninnou metodu. Její princip je jednoduchý:
  - 1 Předpokládáme, že  $A$  má dominantní vlastní číslo.
  - 2 Zvolíme nenulovou počáteční aproximaci  $x^0$  dominantního vlastního vektoru.
  - 3 Vytvoříme posloupnost aproximací ve tvaru

$$x^1 = Ax^0$$

$$x^2 = Ax^1 = A(Ax^0) = A^2x^0$$

$$x^3 = Ax^2 = A(A(Ax^0)) = A^3x^0$$

$$\vdots$$

$$x^k = Ax^{k-1} = A(A^{k-1}x^0) = A^kx^0$$

- K nalezení dominantního vlastního čísla a vektoru můžeme použít mocninnou metodu. Její princip je jednoduchý:
  - 1 Předpokládáme, že  $A$  má dominantní vlastní číslo.
  - 2 Zvolíme nenulovou počáteční aproximaci  $x^0$  dominantního vlastního vektoru.
  - 3 Vytvoříme posloupnost aproximací ve tvaru

$$x^1 = Ax^0$$

$$x^2 = Ax^1 = A(Ax^0) = A^2x^0$$

$$x^3 = Ax^2 = A(A(Ax^0)) = A^3x^0$$

$$\vdots$$

$$x^k = Ax^{k-1} = A(A^{k-1}x^0) = A^kx^0$$

- Tato posloupnost při splnění určitých podmínek konverguje k dominantnímu vlastnímu vektoru.

- Omezme se na reálné symetrické matice  $A$ . Ty mají  $n$  lineárně nezávislých vlastních vektorů a reálná vlastní čísla.

### Vět

Je-li  $\mathbf{x}$  vlastní vektor reálné symetrické matice  $A$ , pak odpovídající vlastní číslo je dáno výrazem

$$\lambda = \frac{(\mathbf{A}\mathbf{x})^T \mathbf{x}}{\mathbf{x}^T \mathbf{x}}.$$

- Omezme se na reálné symetrické matice  $A$ . Ty mají  $n$  lineárně nezávislých vlastních vektorů a reálná vlastní čísla.

### Vět

Je-li  $\mathbf{x}$  vlastní vektor reálné symetrické matice  $A$ , pak odpovídající vlastní číslo je dáno výrazem

$$\lambda = \frac{(\mathbf{Ax})^T \mathbf{x}}{\mathbf{x}^T \mathbf{x}}.$$

Důkaz

$$\frac{(\mathbf{Ax})^T \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \frac{(\lambda \mathbf{x})^T \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \lambda$$



## Věta

Bud'  $A \in \mathbb{R}^{n \times n}$  matice s  $n$  lineárně nezávislými vlastními vektory a dominantním vlastním číslem. Pak existuje nenulový vektor  $x^0$  takový, že posloupnost

$$Ax^0, A^2x^0, A^3x^0, \dots, A^kx^0, \dots$$

konverguje k násobku dominantního vlastního vektoru  $A$ .



## Věta

Bud'  $A \in \mathbb{R}^{n \times n}$  matice s  $n$  lineárně nezávislými vlastními vektory a dominantním vlastním číslem. Pak existuje nenulový vektor  $x^0$  takový, že posloupnost

$$Ax^0, A^2x^0, A^3x^0, \dots, A^kx^0, \dots$$

konverguje k násobku dominantního vlastního vektoru  $A$ .

Důkaz.

- Předpokládejme, že pro vlastní čísla matice  $A$  platí  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots |\lambda_n|$ . Odpovídající vlastní vektory  $v_1, v_2, v_3, \dots, v_n$  jsou lineárně nezávislé a tvoří bázi  $\mathbb{R}^n$ .

## Věta

Bud'  $A \in \mathbb{R}^{n \times n}$  matice s  $n$  lineárně nezávislými vlastními vektory a dominantním vlastním číslem. Pak existuje nenulový vektor  $x^0$  takový, že posloupnost

$$Ax^0, A^2x^0, A^3x^0, \dots, A^kx^0, \dots$$

konverguje k násobku dominantního vlastního vektoru  $A$ .

Důkaz.

- Předpokládejme, že pro vlastní čísla matice  $A$  platí  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots |\lambda_n|$ . Odpovídající vlastní vektory  $v_1, v_2, v_3, \dots, v_n$  jsou lineárně nezávislé a tvoří bázi  $\mathbb{R}^n$ .
- Zvolme vektor  $x^0$  tak, aby koeficient  $c_1$  v lineární kombinaci

$$x^0 = c_1 v_1 + c_2 v_2 + \dots + c_n v_n$$

byl nenulový (pro  $c_1 = 0$  nemusí metoda konvergovat).

## Věta

Bud'  $A \in \mathbb{R}^{n \times n}$  matice s  $n$  lineárně nezávislými vlastními vektory a dominantním vlastním číslem. Pak existuje nenulový vektor  $\mathbf{x}^0$  takový, že posloupnost

$$A\mathbf{x}^0, A^2\mathbf{x}^0, A^3\mathbf{x}^0, \dots, A^k\mathbf{x}^0, \dots$$

konverguje k násobku dominantního vlastního vektoru  $A$ .

Důkaz.

- Předpokládejme, že pro vlastní čísla matice  $A$  platí  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots |\lambda_n|$ . Odpovídající vlastní vektory  $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3, \dots, \mathbf{v}_n$  jsou lineárně nezávislé a tvoří bázi  $\mathbb{R}^n$ .
- Zvolme vektor  $\mathbf{x}^0$  tak, aby koeficient  $c_1$  v lineární kombinaci

$$\mathbf{x}^0 = c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n$$

byl nenulový (pro  $c_1 = 0$  nemusí metoda konvergovat).

- Přenásobme předchozí rovnost maticí  $A$

$$A\mathbf{x}^0 = A(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n)$$

## Věta

Bud'  $A \in \mathbb{R}^{n \times n}$  matice s  $n$  lineárně nezávislými vlastními vektory a dominantním vlastním číslem. Pak existuje nenulový vektor  $\mathbf{x}^0$  takový, že posloupnost

$$A\mathbf{x}^0, A^2\mathbf{x}^0, A^3\mathbf{x}^0, \dots, A^k\mathbf{x}^0, \dots$$

konverguje k násobku dominantního vlastního vektoru  $A$ .

Důkaz.

- Předpokládejme, že pro vlastní čísla matice  $A$  platí  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots |\lambda_n|$ . Odpovídající vlastní vektory  $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3, \dots, \mathbf{v}_n$  jsou lineárně nezávislé a tvoří bázi  $\mathbb{R}^n$ .
- Zvolme vektor  $\mathbf{x}^0$  tak, aby koeficient  $c_1$  v lineární kombinaci

$$\mathbf{x}^0 = c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n$$

byl nenulový (pro  $c_1 = 0$  nemusí metoda konvergovat).

- Přenásobme předchozí rovnost maticí  $A$

$$A\mathbf{x}^0 = A(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n) = c_1A\mathbf{v}_1 + c_2A\mathbf{v}_2 + \dots + c_nA\mathbf{v}_n$$

## Věta

Bud'  $A \in \mathbb{R}^{n \times n}$  matice s  $n$  lineárně nezávislými vlastními vektory a dominantním vlastním číslem. Pak existuje nenulový vektor  $\mathbf{x}^0$  takový, že posloupnost

$$A\mathbf{x}^0, A^2\mathbf{x}^0, A^3\mathbf{x}^0, \dots, A^k\mathbf{x}^0, \dots$$

konverguje k násobku dominantního vlastního vektoru  $A$ .

Důkaz.

- Předpokládejme, že pro vlastní čísla matice  $A$  platí  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots |\lambda_n|$ . Odpovídající vlastní vektory  $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3, \dots, \mathbf{v}_n$  jsou lineárně nezávislé a tvoří bázi  $\mathbb{R}^n$ .
- Zvolme vektor  $\mathbf{x}^0$  tak, aby koeficient  $c_1$  v lineární kombinaci

$$\mathbf{x}^0 = c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n$$

byl nenulový (pro  $c_1 = 0$  nemusí metoda konvergovat).

- Přenásobme předchozí rovnost maticí  $A$

$$A\mathbf{x}^0 = A(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n) = c_1A\mathbf{v}_1 + c_2A\mathbf{v}_2 + \dots + c_nA\mathbf{v}_n = c_1\lambda_1\mathbf{v}_1 + c_2\lambda_2\mathbf{v}_2 + \dots + c_n\lambda_n\mathbf{v}_n.$$

$$A\mathbf{x}^0 = A(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n) = c_1A\mathbf{v}_1 + c_2A\mathbf{v}_2 + \dots + c_nA\mathbf{v}_n = c_1\lambda_1\mathbf{v}_1 + c_2\lambda_2\mathbf{v}_2 + \dots + c_n\lambda_n\mathbf{v}_n.$$

$$\mathbf{A}\mathbf{x}^0 = \mathbf{A}(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n) = c_1\mathbf{A}\mathbf{v}_1 + c_2\mathbf{A}\mathbf{v}_2 + \dots + c_n\mathbf{A}\mathbf{v}_n = c_1\lambda_1\mathbf{v}_1 + c_2\lambda_2\mathbf{v}_2 + \dots + c_n\lambda_n\mathbf{v}_n.$$

$$\Downarrow$$

$$\mathbf{A}^k\mathbf{x}^0 = c_1\lambda_1^k\mathbf{v}_1 + c_2\lambda_2^k\mathbf{v}_2 + \dots + c_n\lambda_n^k\mathbf{v}_n$$

$$\mathbf{A}\mathbf{x}^0 = \mathbf{A}(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n) = c_1\mathbf{A}\mathbf{v}_1 + c_2\mathbf{A}\mathbf{v}_2 + \dots + c_n\mathbf{A}\mathbf{v}_n = c_1\lambda_1\mathbf{v}_1 + c_2\lambda_2\mathbf{v}_2 + \dots + c_n\lambda_n\mathbf{v}_n.$$

$$\Downarrow$$

$$\begin{aligned} \mathbf{A}^k\mathbf{x}^0 &= c_1\lambda_1^k\mathbf{v}_1 + c_2\lambda_2^k\mathbf{v}_2 + \dots + c_n\lambda_n^k\mathbf{v}_n \\ &= \lambda_1^k \left( c_1\mathbf{v}_1 + c_2\frac{\lambda_2^k}{\lambda_1^k}\mathbf{v}_2 + \dots + c_n\frac{\lambda_n^k}{\lambda_1^k}\mathbf{v}_n \right) \end{aligned}$$



$$\mathbf{A}\mathbf{x}^0 = \mathbf{A}(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n) = c_1\mathbf{A}\mathbf{v}_1 + c_2\mathbf{A}\mathbf{v}_2 + \dots + c_n\mathbf{A}\mathbf{v}_n = c_1\lambda_1\mathbf{v}_1 + c_2\lambda_2\mathbf{v}_2 + \dots + c_n\lambda_n\mathbf{v}_n.$$

$$\Downarrow$$

$$\begin{aligned} \mathbf{A}^k\mathbf{x}^0 &= c_1\lambda_1^k\mathbf{v}_1 + c_2\lambda_2^k\mathbf{v}_2 + \dots + c_n\lambda_n^k\mathbf{v}_n \\ &= \lambda_1^k \left( c_1\mathbf{v}_1 + c_2\frac{\lambda_2^k}{\lambda_1^k}\mathbf{v}_2 + \dots + c_n\frac{\lambda_n^k}{\lambda_1^k}\mathbf{v}_n \right) = \lambda_1^k \left( c_1\mathbf{v}_1 + c_2\left(\frac{\lambda_2}{\lambda_1}\right)^k\mathbf{v}_2 + \dots + c_n\left(\frac{\lambda_n}{\lambda_1}\right)^k\mathbf{v}_n \right). \end{aligned}$$

$$\mathbf{A}\mathbf{x}^0 = \mathbf{A}(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n) = c_1\mathbf{A}\mathbf{v}_1 + c_2\mathbf{A}\mathbf{v}_2 + \dots + c_n\mathbf{A}\mathbf{v}_n = c_1\lambda_1\mathbf{v}_1 + c_2\lambda_2\mathbf{v}_2 + \dots + c_n\lambda_n\mathbf{v}_n.$$

$$\Downarrow$$

$$\begin{aligned} \mathbf{A}^k\mathbf{x}^0 &= c_1\lambda_1^k\mathbf{v}_1 + c_2\lambda_2^k\mathbf{v}_2 + \dots + c_n\lambda_n^k\mathbf{v}_n \\ &= \lambda_1^k \left( c_1\mathbf{v}_1 + c_2\frac{\lambda_2^k}{\lambda_1^k}\mathbf{v}_2 + \dots + c_n\frac{\lambda_n^k}{\lambda_1^k}\mathbf{v}_n \right) = \lambda_1^k \left( c_1\mathbf{v}_1 + c_2\left(\frac{\lambda_2}{\lambda_1}\right)^k\mathbf{v}_2 + \dots + c_n\left(\frac{\lambda_n}{\lambda_1}\right)^k\mathbf{v}_n \right). \end{aligned}$$

■ Protože  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots |\lambda_n|$ , platí

$$\left| \frac{\lambda_2}{\lambda_1} \right| < 1, \dots, \left| \frac{\lambda_n}{\lambda_1} \right| < 1.$$

$$\mathbf{A}\mathbf{x}^0 = \mathbf{A}(c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \dots + c_n\mathbf{v}_n) = c_1\mathbf{A}\mathbf{v}_1 + c_2\mathbf{A}\mathbf{v}_2 + \dots + c_n\mathbf{A}\mathbf{v}_n = c_1\lambda_1\mathbf{v}_1 + c_2\lambda_2\mathbf{v}_2 + \dots + c_n\lambda_n\mathbf{v}_n.$$

$$\Downarrow$$

$$\begin{aligned} \mathbf{A}^k\mathbf{x}^0 &= c_1\lambda_1^k\mathbf{v}_1 + c_2\lambda_2^k\mathbf{v}_2 + \dots + c_n\lambda_n^k\mathbf{v}_n \\ &= \lambda_1^k \left( c_1\mathbf{v}_1 + c_2\frac{\lambda_2^k}{\lambda_1^k}\mathbf{v}_2 + \dots + c_n\frac{\lambda_n^k}{\lambda_1^k}\mathbf{v}_n \right) = \lambda_1^k \left( c_1\mathbf{v}_1 + c_2\left(\frac{\lambda_2}{\lambda_1}\right)^k\mathbf{v}_2 + \dots + c_n\left(\frac{\lambda_n}{\lambda_1}\right)^k\mathbf{v}_n \right). \end{aligned}$$

■ Protože  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots |\lambda_n|$ , platí

$$\left| \frac{\lambda_2}{\lambda_1} \right| < 1, \dots, \left| \frac{\lambda_n}{\lambda_1} \right| < 1.$$

■ Pro  $k \rightarrow \infty$  tedy výraz  $\mathbf{A}^k\mathbf{x}^0$  konverguje k  $\lambda_1^k c_1\mathbf{v}_1$ , což je násobek dominantního vlastního vektoru.  $\square$

```
function Mocninna_metoda( $A, x^0$ )
```

$$q^0 = \frac{x^0}{\|x^0\|}$$

```
for  $k = 1, 2, \dots$  do
```

$$x^k = Aq^{k-1}$$

$$q^k = \frac{x^k}{\|x^k\|}$$

$$\lambda = (q^k)^T A q^k \quad \left( = \frac{(x^k)^T A x^k}{\|x^k\|^2} = \frac{(x^k)^T A x^k}{(x^k)^T x^k} \right)$$

```
end for
```

```
end function
```

```
function Mocninna_metoda(A,  $x^0$ )
```

$$q^0 = \frac{x^0}{\|x^0\|}$$

```
for  $k = 1, 2, \dots$  do
```

$$x^k = Aq^{k-1}$$

$$q^k = \frac{x^k}{\|x^k\|}$$

$$\lambda = (q^k)^T A q^k \quad \left( = \frac{(x^k)^T A x^k}{\|x^k\|^2} = \frac{(x^k)^T A x^k}{(x^k)^T x^k} \right)$$

```
end for
```

```
end function
```

- Abychom zachovali numerickou stabilitu, vektor v každé iteraci normujeme.
- Jednou z možností, jak zvolit ukončovací podmínku, je sledovat normu vektoru  $Aq^k - \lambda q^k$ . Ta by se měla blížit nule pro  $k \rightarrow \infty$ .

## Posun spektra

- Má-li  $A$  vlastní čísla  $\lambda_1 > \lambda_2 \geq \dots \geq \lambda_n$  a odpovídající vlastní vektory  $v_1, v_2, \dots, v_n$ , jak vypadají vlastní čísla a vektory matice  $A - \sigma I$ , kde  $\sigma \in \mathbb{R}$ ?

# Posun spektra

- Má-li  $A$  vlastní čísla  $\lambda_1 > \lambda_2 \geq \dots \geq \lambda_n$  a odpovídající vlastní vektory  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ , jak vypadají vlastní čísla a vektory matice  $A - \sigma I$ , kde  $\sigma \in \mathbb{R}$ ?
- Vyjděme z rovnosti

$$A\mathbf{v}_k = \lambda_k \mathbf{v}_k$$

- Odečtěme od obou stran  $\sigma$  násobek vlastního vektoru  $\mathbf{v}_k$ :

$$A\mathbf{v}_k - \sigma I\mathbf{v}_k = \lambda_k \mathbf{v}_k - \sigma \mathbf{v}_k.$$

# Posun spektra

- Má-li  $A$  vlastní čísla  $\lambda_1 > \lambda_2 \geq \dots \geq \lambda_n$  a odpovídající vlastní vektory  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ , jak vypadají vlastní čísla a vektory matice  $A - \sigma I$ , kde  $\sigma \in \mathbb{R}$ ?
- Vyjděme z rovnosti

$$A\mathbf{v}_k = \lambda_k \mathbf{v}_k$$

- Odečtěme od obou stran  $\sigma$  násobek vlastního vektoru  $\mathbf{v}_k$ :

$$A\mathbf{v}_k - \sigma I\mathbf{v}_k = \lambda_k \mathbf{v}_k - \sigma \mathbf{v}_k.$$

$$\Downarrow$$

$$(A - \sigma I)\mathbf{v}_k = (\lambda_k - \sigma)\mathbf{v}_k.$$



# Posun spektra

- Má-li  $A$  vlastní čísla  $\lambda_1 > \lambda_2 \geq \dots \geq \lambda_n$  a odpovídající vlastní vektory  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ , jak vypadají vlastní čísla a vektory matice  $A - \sigma I$ , kde  $\sigma \in \mathbb{R}$ ?

- Vyjděme z rovnosti

$$A\mathbf{v}_k = \lambda_k \mathbf{v}_k$$

- Odečtěme od obou stran  $\sigma$  násobek vlastního vektoru  $\mathbf{v}_k$ :

$$A\mathbf{v}_k - \sigma I\mathbf{v}_k = \lambda_k \mathbf{v}_k - \sigma \mathbf{v}_k.$$

$$\Downarrow$$

$$(A - \sigma I)\mathbf{v}_k = (\lambda_k - \sigma)\mathbf{v}_k.$$

- $\mathbf{v}_k$  je také vlastním vektorem matice  $A - \sigma I$ . Odpovídajícím vlastním číslem je  $\lambda_k - \sigma$ .

- Předchozího poznatku lze využít k nalezení nejmenšího vlastního čísla  $\lambda_n$  symetrické pozitivně definitní matice  $A$ , známe-li její největší vlastní číslo  $\lambda_1$ .

- Předchozího poznatku lze využít k nalezení nejmenšího vlastního čísla  $\lambda_n$  symetrické pozitivně definitní matice  $A$ , známe-li její největší vlastní číslo  $\lambda_1$ .
- Sestavme  $B = A - \lambda_1 I$ .

- Předchozího poznatku lze využít k nalezení nejmenšího vlastního čísla  $\lambda_n$  symetrické pozitivně definitní matice  $A$ , známe-li její největší vlastní číslo  $\lambda_1$ .
- Sestavme  $B = A - \lambda_1 I$ .
- Matice  $B$  má dle předchozího poznatku vlastní čísla  $\lambda_n - \lambda_1, \lambda_{n-1} - \lambda_1, \dots$

- Předchozího poznatku lze využít k nalezení nejmenšího vlastního čísla  $\lambda_n$  symetrické pozitivně definitní matice  $A$ , známe-li její největší vlastní číslo  $\lambda_1$ .
- Sestavme  $B = A - \lambda_1 I$ .
- Matice  $B$  má dle předchozího poznatku vlastní čísla  $\lambda_n - \lambda_1, \lambda_{n-1} - \lambda_1, \dots$
- Předpokládejme, že  $\lambda_n \neq \lambda_{n-1}$ . Protože symetrická pozitivně definitní matice má všechna vlastní čísla kladná (tedy  $0 < \lambda_n < \lambda_{n-1} \leq \dots$ ), můžeme vlastní čísla matice s takto posunutým spektrem seřadit

$$|\lambda_n - \lambda_1| > |\lambda_{n-1} - \lambda_1| \geq \dots$$

- Předchozího poznatku lze využít k nalezení nejmenšího vlastního čísla  $\lambda_n$  symetrické pozitivně definitní matice  $A$ , známe-li její největší vlastní číslo  $\lambda_1$ .
- Sestavme  $B = A - \lambda_1 I$ .
- Matice  $B$  má dle předchozího poznatku vlastní čísla  $\lambda_n - \lambda_1, \lambda_{n-1} - \lambda_1, \dots$
- Předpokládejme, že  $\lambda_n \neq \lambda_{n-1}$ . Protože symetrická pozitivně definitní matice má všechna vlastní čísla kladná (tedy  $0 < \lambda_n < \lambda_{n-1} \leq \dots$ ), můžeme vlastní čísla matice s takto posunutým spektrem seřadit

$$|\lambda_n - \lambda_1| > |\lambda_{n-1} - \lambda_1| \geq \dots$$

- Použijeme-li tedy mocninnou metodu na matici  $B = A - \lambda_1 I$ , nalezneme její dominantní vlastní číslo  $\hat{\lambda} = \lambda_n - \lambda_1$ . Snadno dopočítáme nejmenší vlastní číslo původní matice  $A$ :

$$\lambda_n = \hat{\lambda} + \lambda_1.$$

Děkuji za pozornost

Michal Merta

VŠB – Technická univerzita Ostrava

michal.merta@vsb.cz

27. dubna 2023